



PONTIFICIA
UNIVERSIDAD
CATÓLICA
DE CHILE

Procesamiento de Lenguaje Natural

github.com/marcelomendoza/IIC3670

Marcelo Mendoza

El curso en cinco unidades

1 Leyes del texto, recursos y tareas de NLP

2 Encoders de texto

3 Decoders de texto

4 LLMs, SFT y alineamiento

5 Temas avanzados

01

Leyes del texto, recursos y tareas de NLP

Qué problemas aborda el área, dónde se sitúa y con qué recursos se trabaja

Síntesis: ¿cuáles tareas aborda NLP?

Problemas distintos, una misma materia prima: texto sin estructura.

Casi todas comparten la misma forma: llevar un texto a una representación sobre la que se pueda categorizar, identificar o generar.

Recuperación de información

Ordenar una colección por relevancia frente a una consulta.

Análisis de sentimiento

Asignar polaridad u opinión a un texto o a sus aspectos.

Extracción de información

Identificar entidades, relaciones y eventos para poblar una base estructurada.

Traducción automática


Expresar en una lengua lo dicho en otra, preservando sentido y registro.

Preguntas y respuestas

Responder en lenguaje natural apoyándose en evidencia recuperada.


¿Dónde se ubica NLP?

Entre la inteligencia artificial y la lingüística, con el aprendizaje profundo como herramienta dominante desde 2013.



El enfoque clásico de NLP


Un corpus anotado deja conocimiento lingüístico; el sistema lo aplica sobre texto nuevo para marcarlo.



El principio del mínimo esfuerzo

Antes de mirar las leyes del texto, de dónde salen.

Quien habla gasta lo menos posible: reusa las palabras que ya tiene a mano en vez de buscar la exacta. El texto no es una muestra al azar del idioma, es el resultado de ese principio.



Zipf (1949)



“¿Soy el único por aquí que trata de hacer las cosas con el menor esfuerzo posible y espera un buen resultado?”


La ley de Zipf

$$f_r = \frac{C}{r^\alpha}$$

$r=1,2,3,\dots$ rango de la palabra por frecuencia


$\log f_r = \log C - \alpha \log r$ en log-log es una recta de pendiente $-\alpha$, con α cercano a 1

Ordenadas de más a menos frecuente, la frecuencia cae como una potencia del rango: en Reuters “the” aparece 69.277 veces y “of” 36.779, casi la mitad. Más abajo la caída es algo más lenta que $1/r$, es decir α un poco menor que 1.



Palabras ordenadas por frecuencia

La forma de la ley




Reuters: las 30 palabras más frecuentes

Zipf en log-log: estimar α y C

$$\hat{\alpha} = - \frac{\sum_r (x_r - \bar{x})(y_r - \bar{y})}{\sum_r (x_r - \bar{x})^2}$$

$$\log \hat{C} = \bar{y} + \hat{\alpha} \bar{x} \quad x_r = \log r, \quad y_r = \log f_r$$



La recta

En log-log la ley es $\log f_r = \log C - \alpha \log r$: la pendiente vale $-\alpha$ y el intercepto, el valor en $r = 1$, vale $\log C$.

El ajuste

Mínimos cuadrados sobre los pares $(\log r, \log f_r)$. En Reuters da $\alpha = 0,96$ y $C = 1,39 \cdot 10^5$.

$$f_r = \frac{n}{r^\alpha H_V(\alpha)} \quad H_V(\alpha) = \sum_{j=1}^V \frac{1}{j^\alpha} \quad \alpha \rightarrow 1 \Rightarrow H_V \approx \ln V + \gamma$$


La ley de Heaps

$$V = k n^{\beta}$$

n =tokens del texto, V =palabras distintas

$$\log V = \log k + \beta \log n$$

otra recta en log-log; típicamente $0,4 \leq \beta \leq 0,6$



El vocabulario nunca deja de crecer

Siguen apareciendo palabras nuevas por más texto que se acumule: nombres propios, cifras, errores de tipeo.

Pero crece cada vez más lento

Duplicar el texto multiplica el vocabulario por 2^{β} , no por 2. Aquí $\beta = 0,52$ y $k = 20$.

k y β van atados

Un β mayor exige un k menor para pasar por los mismos puntos: con $\beta = 0,49$ este mismo corpus da $k = 29$.

La otra cara de Zipf

La cola de palabras raras es inagotable: Zipf la mira por frecuencia, Heaps por acumulación.

Niveles de abstracción del lenguaje

Cada nivel tiene su unidad de análisis y su disciplina; NLP los recorre todos.

Nivel de la lengua	Unidad de estudio	Disciplina
Morfológico	la palabra	Morfología
Sintáctico	la oración	Sintaxis
Léxico-semántico	el significado	Lexicología y semántica
Textual	el texto	Analítica textual

Nivel morfológico: el monema

La unidad más pequeña que tiene a la vez significante y significado.



Lexema y morfema

El lexema carga el significado y es la parte que se repite en la familia de la palabra: perro, perra, perrera. El morfema aporta la cualidad: género, número, tiempo, persona.

Por qué importa aquí

Casi todo el procesamiento básico consiste en decidir qué parte de la palabra conservar. El stemming corta hasta el lexema de forma aproximada; la lematización lo hace con un diccionario.

Palabras variables e invariables

La morfología divide las categorías gramaticales según admitan o no flexión.

Variables

Cambian de forma según género, número, persona o tiempo

Sustantivo

casa → casas

Adjetivo

alto → alta → altísimo

Verbo

cantar → canté → cantaríamos

Artículo y pronombre

el → la → los; yo → me → mí

Invariables

Tienen una sola forma

Preposición

de, con, para, sobre

Conjunción

y, pero, aunque, porque

Adverbio

ayer, aquí, rápidamente

Interjección



¡ah!, ¡ojalá!

Por qué la distinción importa en NLP

Las variables son las que explotan el vocabulario: una sola entrada de diccionario genera decenas de formas, y son el blanco de la lematización. Las invariables, en cambio, son casi todas stopwords, las más frecuentes según Zipf, y suelen ser lo primero que se descarta.

Nivel sintáctico: la oración

Las palabras no se ordenan en fila: se agrupan en constituyentes, y esos constituyentes se anidan.



Primero, la categoría

Etiquetar cada palabra con su categoría gramatical es el paso previo: el POS tagging.

Después, la estructura

SN es sintagma nominal y SV sintagma verbal. «El perro» funciona como una unidad: se puede reemplazar entero por «él» sin romper la oración.


Por qué importa

El orden de las palabras no basta para saber quién hace qué; la estructura sí.

Nivel morfosintáctico: reconocer entidades

Entre la palabra y la oración: la forma de la palabra no alcanza, el contexto decide.

	Neruda	nació	en	Parral	en	1904
POS	PROPN	VERB	ADP	PROPN	ADP	NUM
NER	PER	O	O	LUG	O	FECHA



Dos capas sobre los mismos tokens

El POS tagging dice qué es cada palabra gramaticalmente. El NER dice a qué se refiere: persona, lugar, organización, fecha.

Por qué el POS no basta

«Neruda» y «Parral» son ambos PROPN y sin embargo uno es persona y el otro lugar. La categoría gramatical acota el problema, no lo resuelve.


Por qué es morfosintáctico

La pista morfológica es la mayúscula inicial y la sintáctica es el vecindario: tras «nació en» viene un lugar. Ninguno de los dos niveles solo alcanza.


Nivel léxico-semántico: hponimia y meronimia

Las palabras están ordenadas por relaciones de inclusión.

Dos inclusiones distintas que conviene no confundir: la hponimia es de clase (el hipónimo es un caso del hiperónimo) y la meronimia es de composición (el merónimo es una pieza del holónimo).



hponimia: una rosa es una flor



meronimia: un pétalo es parte de una flor

Nivel semántico: una forma, varios sentidos

La relación inversa a la sinonimia: si el synset agrupa formas que significan lo mismo, aquí una forma se reparte entre synsets.



Polisemia

Un origen y sentidos emparentados, que se estiran por metáfora: el pie sostiene al cuerpo, a la montaña y a la página.

Homonimia

Dos palabras que llegaron por caminos distintos y terminaron escribiéndose igual. «Llama» viene del latín flamma, del quechua y del verbo llamar.

Lematización: llevar cada forma a su lema

El lema es la entrada de diccionario; el stem es lo que queda tras cortar sufijos con reglas.

Forma	Porter (stemming)	WordNet sin POS	WordNet con POS
running	run	running	run (v)
better	better	better	good (a)
studies	studi	study	study (v)
mice	mice	mouse	mouse (n)
was	wa	wa	be (v)

El lematizador de WordNet no aplica reglas: busca la palabra en la base y devuelve una forma que sí existe, por eso nunca inventa «studi» ni «wa». Pero necesita la categoría gramatical; sin ella asume sustantivo. Primero POS, después lematizar.

WordNet

Una base léxica del inglés organizada por significados, no por palabras.

dog.n.01

lemas: dog, domestic_dog, Canis_familiaris

«a member of the genus Canis (probably descended from the common wolf) that has been domesticated by man since prehistoric times»

hiperónimo canine.n.02, domestic_animal.n.01

hipónimos basenji.n.01, corgi.n.01, cur.n.01, ...

holónimo canis.n.01, pack.n.06

merónimo flag.n.07

Qué es

117.659 synsets y 147.306 lemas. Un synset agrupa los sinónimos de un mismo significado, con su definición y sus relaciones.

Cómo se construyó y dónde está


A mano, en Princeton, desde 1985, bajo la dirección de George Miller. En wordnet.princeton.edu y dentro de NLTK, en `nltk.corpus.wordnet`.

Cómo lematiza

El módulo `morph` quita sufijos según la categoría, consulta una lista de excepciones y solo acepta el resultado si figura en la base.


WordNet es una red enorme

La misma vecindad de «emotion» a tres escalas: 117.659 synsets conectados entre sí.



BabelNet: WordNet fusionada con la web semántica

Un mismo concepto, una sola entrada, en cientos de idiomas y con las entidades que a WordNet le faltan.



BabelNet, por dentro

BabelNet

v5.3

Login | Preferencias

procesamiento de lenguaje natural

Spanish

Traduzca al...

bn:00045156n | Sustantivo Concepto | Categorías: Procesamiento de le...

ES procesamiento de lenguajes naturales

Procesamiento del lenguaje natural

procesamiento de lenguaje natural

Procesamiento de lenguas naturales



See more

El procesamiento de lenguaje natural o de lenguas naturales,[1][2] abreviado PLN[3][4], es un campo de las ciencias de la computación, de la inteligencia artificial y de la lingüística que estudia las interacciones entre las computadoras y el lenguaje humano, así como los detalles computacionales de las lenguas naturales.

Wikipedia

English: computer science



DEFINICIONES

RELACIONES

FUENTES

Spanish > Más idiomas...

IS A

informática • especialidad • especialidad • campo de estudio • disciplina académica +4 relations

HAS PART

lingüística computacional • procesamiento de lenguajes naturales • word embedding

PART OF

procesamiento de lenguajes naturales

HAS KIND

EN Morphological parsing • codificación de caracteres chinos • reconocimiento del habla • generación de lenguajes naturales • segmentación del texto +6 relations

FACET OF

Extracción de la información

STUDIES


correferencia • semántica léxica • traducción automática • EN relationship extraction • reconocimiento de nombres de entidades +19 relations

<https://babelnet.org/>

22

Stopwords

Poquísimas palabras que ocupan un tercio del texto y casi no distinguen documentos.



porción que aportan las 146 stopwords presentes

Qué son

Artículos, preposiciones, conjunciones y auxiliares: las invariables de la lámina 13, que son también la cabeza de la curva de Zipf.

Qué se gana al quitarlas


En Reuters son 146 palabras: el 0,5 % del vocabulario y el 34,3 % de los tokens. Quitarlas achica el texto a un tercio y deja un vocabulario controlado.

Cuándo no conviene

Cuando la estructura importa. «No me gustó» sin la negación cambia de signo, y en búsqueda de frases exactas hay que conservarlas.

El pipeline de preprocesamiento

De texto crudo a vocabulario, con etapas que se pueden omitir según la tarea.



los caminos punteados son atajos: cada etapa opcional se puede omitir

La matriz término-documento

El vocabulario controlado se vuelve una tabla: una fila por término, una columna por documento.


The diagram illustrates a term-document matrix. The rows represent terms (términos) and the columns represent documents (documentos). The matrix is annotated with arrows: a horizontal arrow from 'documentos' points to the column headers, and a vertical arrow from 'términos' points to the row headers. A blue box highlights the second column (Julio Cesar), with an arrow labeled 'vectorización' pointing to it, indicating that each column represents a document's vector of term frequencies.

documentos →	Antonio y Cleopatra	Julio Cesar	La Tempestad	Hamlet	Otelo	Macbeth	...
Antonio	157	73	0	0	0	1	
Brutus	4	157	0	2	0	0	
Cesar	232	227	0	2	1	0	
Calpurnia	0	10	0	0	0	0	
Cleopatra	57	0	0	0	0	0	
...		...					
términos ↑							

vectorización

El modelo de espacio vectorial

Cada término es una dimensión; cada documento, un punto en ese espacio de V dimensiones.



La función de pesos

La celda de la matriz no tiene por qué ser la frecuencia cruda.

$$\vec{d}_j = (w_{1,j}, \dots, \mathbf{w}_{i,j}, \dots, w_{V,j}) \quad \text{una coordenada por término del vocabulario}$$

$$\mathbf{w}_{i,j} = f(t_i, d_j) \quad f \text{ es la función de pesos}$$

A diagram showing a 3x3 grid. The center cell is shaded blue. A downward-pointing arrow is positioned above the center cell. The letter X is located in the bottom-right cell of the grid.

Qué hay en cada celda

Un peso w que mide la importancia del término i en el documento j . Elegir esa función es la decisión de diseño del modelo.

Por qué no la frecuencia cruda

Un término que aparece en todos los documentos no distingue ninguno, y uno que aparece diez veces no importa diez veces más que uno que aparece una vez.

Qué viene

Las funciones clásicas resuelven esas dos cosas: amortiguar la frecuencia y premiar lo raro.

Funciones de pesos

Cuatro maneras de llenar la celda, de la más ingenua a la que se usó durante treinta años.

$$\text{tf}_{i,j} = \frac{f_{i,j}}{\max_l f_{l,j}} \quad \text{normalizada por el término más frecuente del docum}$$

$$\text{tf}_{i,j}^{\log} = 1 + \log_{10} f_{i,j} \quad (\text{si } f_{i,j} > 0) \quad \text{amortigua las frecuencias altas}$$

$$\text{idf}_i = \log_{10} \frac{N}{n_i} \quad \text{premia lo raro: } n_i \text{ documentos contienen } t_i, \text{ de } N$$

$$w_{i,j} = \text{tf}_{i,j} \cdot \text{idf}_i \quad \text{tf-idf: frecuente aquí, raro en el resto de la colección}$$

El eje frecuencia

tf mide cuánto pesa el término dentro del documento. La versión logarítmica amortigua las frecuencias altas.

El eje rareza

idf mira la colección entera: un término en pocos documentos discrimina mucho. Si aparece en todos, $\log(N/n_i) = 0$ y el término se anula solo.

El producto

tf-idf pesa alto lo que es frecuente aquí y raro afuera. Es la intuición completa en una multiplicación.

BM25

La función de pesos que sigue siendo la referencia en recuperación de información.

$$w_{i,j} = \underbrace{\frac{f_{i,j} (k_1 + 1)}{k_1 \left[(1 - b) + b \frac{l(d_j)}{l_{avg}} \right] + f_{i,j}}}_{\text{tf saturada y normalizada por largo}} \cdot \underbrace{\log \frac{N}{n_i}}_{\text{idf}} \quad b \approx 0,75, \quad k_1 \approx 1,2$$

Satura la frecuencia

El primer factor crece con f pero tiende a un techo: pasar de 1 a 2 apariciones importa mucho, de 20 a 21 casi nada. Es lo que k_1 controla.

Corrige por largo

Un documento largo tiene más apariciones de todo solo por ser largo. El cociente $l(d)/l_{avg}$ lo penaliza, y b regula cuánto: con $b = 0$ no corrige, con $b = 1$ corrige del todo.


Los valores vienen de medir

$b \approx 0,75$ y $k_1 \approx 1,2$ no se derivan de ninguna teoría: son el resultado de barrer valores contra colecciones con juicios de relevancia.

Ranquear por ángulo, no por distancia

La consulta también es un vector; los documentos se ordenan por cuánto apuntan hacia ella.

$$\cos(\vec{q}, \vec{d}) = \frac{\vec{q} \cdot \vec{d}}{\|\vec{q}\| \|\vec{d}\|} = \frac{\sum_{i=1}^V q_i d_i}{\sqrt{\sum_{i=1}^V q_i^2} \sqrt{\sum_{i=1}^V d_i^2}}$$



Por qué el ángulo

La distancia euclidiana castiga a los documentos largos, que tienen vectores más largos aunque hablen de lo mismo. El ángulo ignora la magnitud.

Cómo se lee la figura

Los tres documentos y la consulta salen del origen. d_2 es el más cercano en ángulo a q , aunque d_1 o d_3 puedan estar más cerca en distancia.

El coseno

Vale 1 cuando los vectores apuntan igual y 0 cuando no comparten ningún término. Con pesos no negativos nunca es menor que 0.