



PONTIFICIA
UNIVERSIDAD
CATÓLICA
DE CHILE

Procesamiento de Lenguaje Natural

github.com/marcelomendoza/IIC3670

Marcelo Mendoza


02

Encoders de texto

Cómo se lleva un documento a un vector y qué se puede decidir a partir de él

El documento como vector


Cada término es una dimensión; cada documento, un punto. Clasificar es partir ese espacio en regiones.



El vector bolsa de palabras (bag of words)

El documento es un vector de conteos sobre el vocabulario; la etiqueta, una de K clases.

«el árbitro anuló el gol»




Modelos lineales

Una suma pesada de las coordenadas del documento: un número por documento.

$$s = \mathbf{w}^\top \mathbf{x} = \sum_{i=0}^V \mathbf{w}_i x_i \quad \text{\textit{x}}=\text{el documento}, \quad \text{\textit{w}}=\text{los parámetros}, \quad s=\text{la puntuación}$$

$x_0 = 1$ coordenada constante, para que $\mathbf{w}_0$ sea el sesgo



Un peso por término

w tiene una coordenada por dimensión del espacio, es decir un peso por palabra del vocabulario. Aprender es fijar esos números.

El sesgo

$x_0 = 1$ es una coordenada constante que se agrega al documento, y w_0 corre la frontera para que no tenga que pasar por el origen.

La frontera es un hiperplano


$s = 0$ parte el espacio en dos regiones. w es perpendicular a la frontera y apunta hacia el lado positivo.

Modelos lineales

Los tres modelos comparten la puntuación y se diferencian en qué hacen con ella.

$$y = \theta(s) = \theta(w^\top x)$$


sign(s) $\{-1, +1\}$



Escalón: el perceptrón

Entrega solo el signo de la puntuación. Decide, pero no dice con cuánta confianza, y su salto no es derivable.


s $(-\infty, \infty)$



Identidad: regresión lineal

Deja la puntuación cruda, en todo el rango real. Sirve para predecir una magnitud, no una clase.

$\theta(s)$ $[0, 1]$



Logística: regresión logística

Proyecta la puntuación en el intervalo $[0, 1]$ y permite leerla como probabilidad. Es suave, y por eso se entrena con gradiente.


Regresión logística

La salida deja de ser una decisión y pasa a ser una probabilidad.

$$h(x) = \theta(w^\top x) = \frac{1}{1 + e^{-w^\top x}} \quad h(x) = \mathbb{P}[y = +1 | x]$$

$$\theta(-s) = 1 - \theta(s)$$

la probabilidad de la otra clase sale de la misma cuenta



Qué se estima

No la clase, sino $P[y = +1 | x]$: cuán seguro está el modelo de que el documento es de deportes. La decisión se toma después, con un umbral.

Qué es un buen modelo

Sobre el corpus anotado, $h(x)$ cerca de 1 en los documentos con $y = +1$ y cerca de 0 en los de $y = -1$. Entrenar es empujarlos a los extremos de la curva.

Una sola cuenta para las dos clases


$\theta(-s) = 1 - \theta(s)$: la probabilidad de la clase contraria no necesita otro modelo, sale de dar vuelta el signo de la puntuación.

La función de pérdida: entropía cruzada binaria

Un número que mide cuánto se equivoca el modelo, y que sabe distinguir equivocarse de equivocarse con seguridad.

$$\mathcal{L}(\mathbf{w}) = -\frac{1}{N} \sum_{n=1}^N \left[y_n \log h(x_n) + (1 - y_n) \log (1 - h(x_n)) \right]$$

$y_n \in \{0,1\}$ la etiqueta, $h(x_n) = \theta(\mathbf{w}^\top x_n)$ lo que predice el modelo



De los dos términos, uno se apaga

La etiqueta hace de interruptor: con $y = 1$ queda $\log h(x)$ y con $y = 0$ queda $\log(1 - h(x))$. Es un solo término por documento, escrito sin partir en casos.

Por qué el logaritmo


Se pide al modelo máxima probabilidad sobre el corpus anotado: el producto de las probabilidades se vuelve suma al tomar log, y maximizarla es minimizar L .

Qué castiga

Error por poco cuesta poco; darle probabilidad casi nula a lo que sí ocurrió cuesta infinito.

La pérdida, caso por caso

Los cuatro casos posibles, y de dónde sale el número en cada uno.



p es la probabilidad que el modelo le da a la etiqueta correcta: $h(x)$ si $y = 1$, y $1 - h(x)$ si $y = 0$.

$\log p$ nunca es positivo, porque $p \leq 1$. El signo menos lo da vuelta: la pérdida crece cuando el modelo se equivoca.

El gradiente de la pérdida

Por la regla de la cadena: w entra en la pérdida a través de s y de h , así que son tres derivadas encadenadas.

$$\mathbf{1} \quad \frac{\partial \mathcal{L}_n}{\partial h} = - \left[\frac{y}{h} - \frac{1-y}{1-h} \right] = - \frac{y(1-h) - (1-y)h}{h(1-h)} = \frac{h-y}{h(1-h)}$$

$$\mathbf{2} \quad \frac{\partial h}{\partial s} = \frac{\partial}{\partial s} (1 + e^{-s})^{-1} = -(1 + e^{-s})^{-2} \cdot (-e^{-s}) = \frac{e^{-s}}{(1 + e^{-s})^2}$$

$$= \frac{1}{1 + e^{-s}} \cdot \frac{e^{-s}}{1 + e^{-s}} = h(1-h)$$

$$\text{porque } \frac{e^{-s}}{1+e^{-s}} = \frac{(1+e^{-s})-1}{1+e^{-s}} = 1 - \frac{1}{1+e^{-s}} = 1 - h$$

$$\mathbf{3} \quad \frac{\partial s}{\partial \mathbf{w}} = \frac{\partial}{\partial \mathbf{w}} \sum_{i=0}^V w_i x_i = x$$

$$\frac{\partial \mathcal{L}_n}{\partial \mathbf{w}} = \frac{h-y}{h(1-h)} \cdot h(1-h) \cdot x = (h-y)x$$

Descenso de gradiente


Bajar por la pendiente: el procedimiento que convierte la pérdida en un valor de w .

$$\mathbf{w} \leftarrow \mathbf{w} - \eta \nabla \mathcal{L}(\mathbf{w})$$

η =la tasa de aprendizaje: el largo del paso

$$\nabla \mathcal{L}(\mathbf{w}) = \frac{1}{N} \sum_{n=1}^N (h(x_n) - y_n) x_n$$

el error de cada documento, por el documento



El gradiente es la pendiente

Dice cuánto sube la pérdida si sube cada peso. Apunta hacia arriba, así que para bajar se resta, y por eso el signo menos en la regla.

La regla queda legible

El paso de cada documento es su error por el documento: si predijo de más se le resta, y si de menos, se le suma. Es la regla del perceptrón, ahora con un error graduado en vez de un signo.

La tasa de aprendizaje


η fija el largo del paso. Muy chica, no se avanza; muy grande, se pasa del mínimo y la pérdida se dispara.

Regresión logística multinomial

De dos clases a K : una puntuación por clase, y la softmax las convierte en una distribución.

$s_k = \mathbf{w}_k^\top \mathbf{x}$ una puntuación por clase: $\mathbf{w}$ pasa de vector a matriz de K filas

$p_k = \frac{e^{s_k}}{\sum_{j=1}^K e^{s_j}}$ $p_k > 0$ y $\sum_k p_k = 1$: una distribución sobre las K clases



las tres probabilidades suman 1

argmax → deportes

Un vector de pesos por clase

$\mathbf{w}$ deja de ser un vector y pasa a ser una matriz de K filas. Cada fila es un modelo lineal como el que ya vimos, y el documento recibe K puntuaciones en vez de una.

Intercambiabilidad: el orden se pierde

La bolsa de palabras entrega el mismo vector para cualquier reordenamiento del documento.

$$x(w_1, \dots, w_n) = x(w_{\pi(1)}, \dots, w_{\pi(n)}) \quad \text{para cualquier permutación } \pi \text{ de las palabras}$$
$$\implies f(x(d)) = f(x(\pi d)) \quad \text{ningún modelo } f \text{ puede deshacerla}$$

«España venció a Argentina»

«Argentina venció a España»

el orden se descarta ↓

a	argentina	españa	venció
1	1	1	1

el mismo vector para las dos
dicen lo contrario y el modelo
no tiene con qué distinguirlas

Qué quiere decir

El vector solo cuenta ocurrencias. Las $n!$ maneras de reordenar las palabras de un documento caen todas en el mismo punto del espacio, y el orden, donde vive buena parte del significado, no entra.

No lo arregla un modelo mejor

Dos documentos con el mismo vector reciben la misma puntuación, la misma probabilidad y la misma etiqueta. Ninguna arquitectura puede separar lo que la entrada ya confundió.

Dónde duele y dónde no

Para clasificar por tema casi da lo mismo: el tema está en qué palabras aparecen. Para sentimiento, negación y roles, quién le hizo qué a quién, es fatal.

n-gramas: una ventana que recorre el texto

Contar secuencias de n palabras consecutivas, y no palabras sueltas, devuelve parte del orden al vector.

$$g_i = (w_i, w_{i+1}, \dots, w_{i+n-1}) \quad n \text{ palabras consecutivas a partir de la posición } i$$

$$i = 1, 2, \dots, N - n + 1 \quad \text{un documento de } N \text{ palabras da } N - n + 1 \text{ n-gramas}$$

una ventana de 2 palabras recorre el texto

España **venció** a Argentina → (España, venció)

España **venció** **a** Argentina → (venció, a)

España venció **a** **Argentina** → (a, Argentina)

cada posición produce un 2-grama

«Argentina venció a España» da otros tres

Qué es un n-grama

Una secuencia de n palabras consecutivas. Con $n = 1$ son las palabras sueltas de siempre; con $n = 2$, bigramas; con $n = 3$, trigramas.

La ventana deslizante

Una ventana de largo n se pone al principio del texto y avanza de a una palabra. Cada posición entrega un n-grama, y el recorrido termina cuando la ventana llega al final.

El vocabulario se dispara

Los n-gramas pasan a ser las coordenadas del vector, y hay muchísimos más que palabras. El vector gana orden local y pierde en tamaño y en datos: casi todos los bigramas se ven una o dos veces.

Skip-gramas: objetivo y contexto

La palabra del centro de la ventana se empareja con cada una de las que la rodean, estén pegadas o no.

(w_i, w_{i+j}) con $0 < |j| \leq m$ w_i =objetivo, w_{i+j} =cada palabra del contexto

ventana de $2m + 1$ palabras

$m=2$: los pares con $|j|=2$ saltan una palabra

la del centro es el objetivo; las de alrededor, el contexto



en acento, los pares que saltan una palabra:
son **bigramas no consecutivos**, y de ahí el nombre **skip-grama**

Un objetivo y su contexto

La ventana ya no entrega un bloque de n palabras seguidas. Ahora la del centro es el objetivo y cada una de las otras arma un par con ella, así que una posición produce varios pares.

Bigramas que saltan

Con radio 2, los pares con las palabras a distancia 1 son consecutivos, pero los de distancia 2 se saltan la palabra del medio. Son bigramas no consecutivos, y de ahí el nombre.

Para qué sirve

Cada par es un ejemplo de entrenamiento: «esta palabra aparece cerca de esta otra». Un corpus sin anotar se vuelve millones de ejemplos, sin que nadie etiqüete nada.

word2vec: el modelo skip-gram


Un clasificador que predice el contexto a partir del objetivo. Lo que interesa no es la predicción, sino los pesos que quedan.

$$p(c | o) = \frac{e^{u_c^\top v_o}}{\sum_{k=1}^V e^{u_k^\top v_o}}$$

v_o =el vector del objetivo, u_c =el del contexto

$$\mathcal{L} = -\frac{1}{|S|} \sum_{(o,c) \in S} \log p(c | o)$$

promediado sobre los $|S|$ pares que salen del corpus



se entrena para predecir el contexto,
pero lo que queda es W_{in} : el embedding

Es la regresión logística multinomial

Dado el objetivo hay que elegir cuál de las V palabras aparece cerca: es la regresión logística multinomial, entrenada con los pares de skip-gramas.

La capa oculta es el embedding

Al multiplicar por la matriz de entrada, el one-hot no suma nada: solo elige una fila. Esa fila, de unos cientos de números, es el vector de la palabra.

La tarea es una excusa

Nadie quiere predecir contexto. Terminado el entrenamiento se descarta la salida y se guarda esa tabla de vectores, que es lo que se buscaba.

Dos capas, dos matrices, dos vectores por palabra

Cada palabra aparece dos veces en la red: una como objetivo y otra como contexto.

$W_{in} \in \mathbb{R}^{V \times d}$: la fila o es v_o



la palabra cuando hace de objetivo

$W_{out} \in \mathbb{R}^{d \times V}$: la columna c es u_c

la misma palabra cuando hace de contexto

$$s = u_c^\top v_o$$

el producto punto de los dos



las dos son tablas de vectores de largo d

Una matriz por capa

La primera lleva del one-hot al vector denso; la segunda, del vector denso a las V puntuaciones. Cada una guarda V por d números.

Cada palabra tiene dos vectores

El de objetivo es su fila en la primera matriz; el de contexto, su columna en la segunda. La puntuación de un par es el producto punto entre ambos.

Las dos sirven de embedding

Lo habitual es quedarse con la primera, pero la segunda también es una tabla de vectores de largo d . Sumarlas o promediarlas suele andar algo mejor.

Entrenar con muestreo negativo

La softmax sobre V se reemplaza por una pregunta binaria: ¿este par salió del corpus o lo inventamos?

$$h = P(+ \mid o, c) = \sigma(u_c^\top v_o)$$

¿el par es de verdad?

$$\mathcal{L} = -\frac{1}{|S|} \sum_{(o,c) \in S} \left[\mathbf{y} \log h + (1 - \mathbf{y}) \log (1 - h) \right]$$

$\mathbf{y}=1$ observado, $\mathbf{y}=0$ sorteado

«... mermelada de damasco ...»

objetivo: damasco

par	y	el gradiente
-----	---	--------------

(damasco, mermelada)	1	acerca
----------------------	---	--------

(damasco, matriz)	0	aleja
-------------------	---	-------

(damasco, Tolstói)	0	aleja
--------------------	---	-------

el corpus solo trae el positivo:

los dos negativos se sortean

De V clases a una pregunta binaria

En vez de elegir entre V palabras hay que decidir si el par es observado o fabricado. El costo de cada paso deja de depender del tamaño del vocabulario.

Los negativos hay que inventarlos

El corpus solo entrega pares que ocurren. Por cada positivo se sortean k palabras y se arman con ellas k pares con etiqueta 0.

Reaparece la entropía cruzada binaria

Es la misma fórmula de antes, sin cambiarle una letra. Lo único distinto es qué es h, que ahora sale del producto punto, y qué dice la etiqueta.

De dónde salen los negativos

Se sortean con las frecuencias del corpus, pero aplanadas por un exponente menor que uno.

$$P(w) = \frac{f(w)^\beta}{\sum_{j=1}^V f(w_j)^\beta}$$

$f(w)$ = la frecuencia de w en el corpus

$0 < \beta < 1$, $\beta = \frac{3}{4}$ $\beta=1$ sortearía por frecuencia

frecuencias de ejemplo, sobre tres órdenes de magnitud

palabra	$f(w)$	$\beta = 1$	$\beta = 3/4$	cambia
de	0,900	0,900	0,823	0,9×
gol	0,090	0,090	0,146	1,6×
matriz	0,009	0,009	0,026	2,9×
Tolstói	0,001	0,001	0,005	5,0×

la palabra más rara se vuelve cinco veces más probable;
la más frecuente, algo menos

Al azar, pero no uniforme

Sortear con probabilidad uniforme daría casi siempre palabras rarísimas, que no enseñan nada porque nunca aparecerían en ningún contexto.

Tampoco por frecuencia pura

Con $\beta = 1$ los negativos serían casi siempre artículos y preposiciones, que acompañan a todo y tampoco discriminan.

El exponente aplanar


Con $\beta = 3/4$ las palabras raras suben y las muy frecuentes bajan.

Regularidades: las analogías

Las relaciones entre palabras quedan guardadas como direcciones, y se pueden sumar y restar.

$$b^* = \arg \max_{w \in V} \text{sim}(w, b - a + a^*) \quad a:a^* :: b:b^*$$

rey - hombre + mujer $\approx$ reina la diferencia carga la relación



La diferencia es la relación

El vector que va de hombre a mujer es casi el mismo que va de rey a reina, de actor a actriz o de padre a madre. El género quedó como una dirección del espacio.

Se resuelve con aritmética

Para completar «hombre es a mujer como rey es a...» se calcula rey menos hombre más mujer y se busca la palabra más parecida al resultado.

Nadie la programó

El entrenamiento solo acercaba pares observados y alejaba sorteados. Que las relaciones queden alineadas es una consecuencia, no un objetivo.


Regularidades: el cuarto excluido

Dada una lista de palabras, encontrar la que no calza con las demás sin saber nada de su significado.

$$w^* = \arg \max_{w \in L} \left\| \sum_{v \in L \setminus w} v \right\|$$

L =la lista de palabras

las que quedan apuntan al mismo lado



el máximo se da al sacar «mermelada»

Se saca una por vez

Para cada palabra de la lista se suman los vectores de las otras y se mide el largo de esa suma. Son tantas cuentas como palabras haya.

La no relacionada deja la suma más larga

Al sacarla, las que quedan apuntan casi al mismo lado y se refuerzan. Al sacar cualquier otra, la no relacionada sigue adentro tirando hacia otro lado y acorta la suma.

Solo geometría

No hay diccionario ni categorías: el modelo nunca supo que mermelada es comida. La distinción salió de que aparece en contextos distintos.