IIC3670 Procesamiento de Lenguaje Natural

https://github.com/marcelomendoza/IIC3670

Clasificación con word embeddings

| V |

```
inputs = Input(shape=(max_tokens, ))

embeddings_layer = Embedding(input_dim=len(tokenizer.index_word)+1,
output_dim=embed_len, input_length=max_tokens, trainable=False,
weights=[glove_50_embeddings])

dense1 = Dense(128, activation="relu")
dense2 = Dense(64, activation="relu")
dense3 = Dense(len(classes), activation="softmax")

x = embeddings_layer(inputs)
x = tensorflow.reduce_sum(x, axis=1)
x = dense1(x)
x = dense2(x)
outputs = dense3(x)

model = Model(inputs=inputs, outputs=outputs)
```

forward

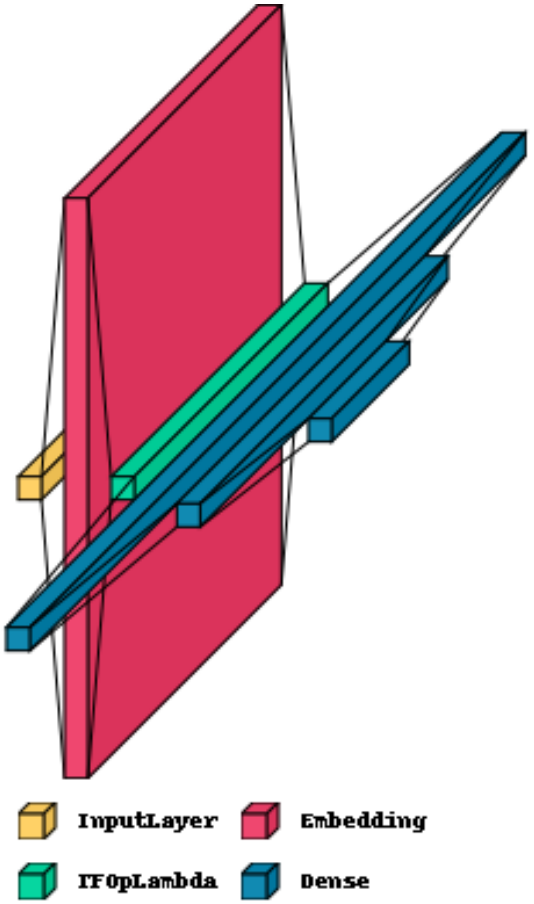

Clasificación con word embeddings

Modelo preentrenado, vectores densos

Multi-hot vector

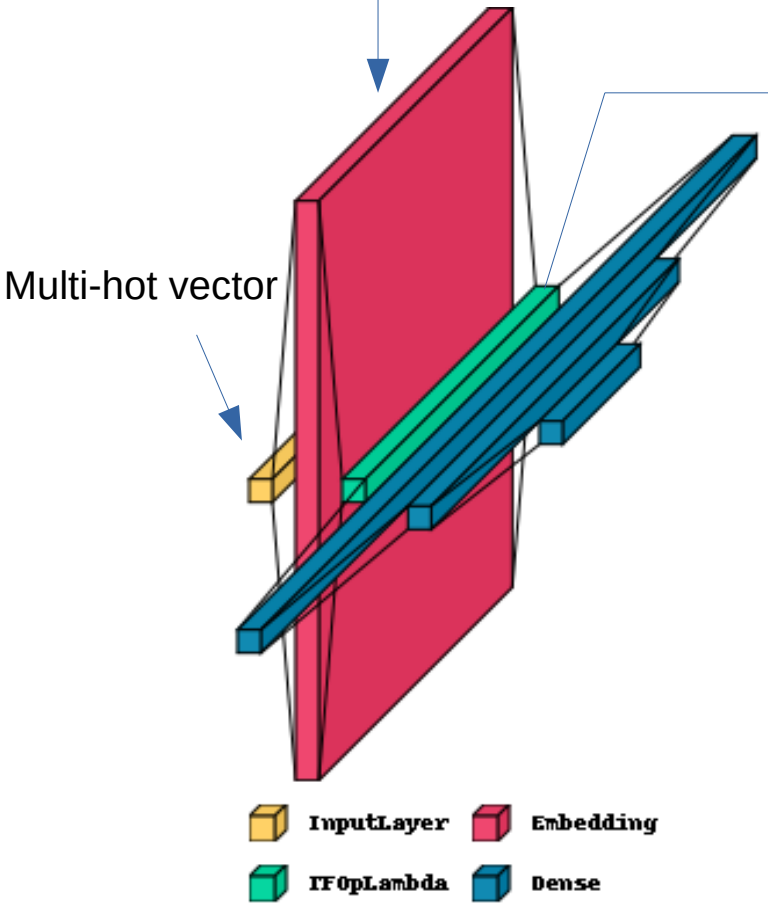

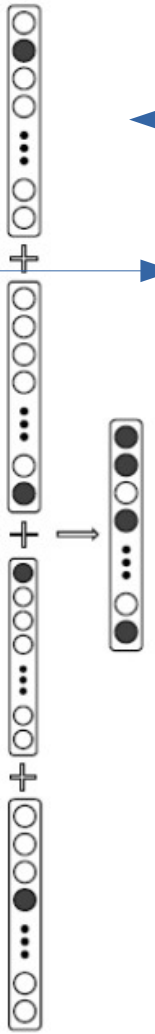

Word embeddings

tensorflow.reduce_sum(x, axis=1)

One hot x E:

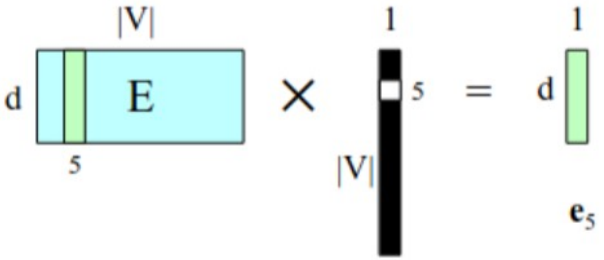

Clasificación con word embeddings

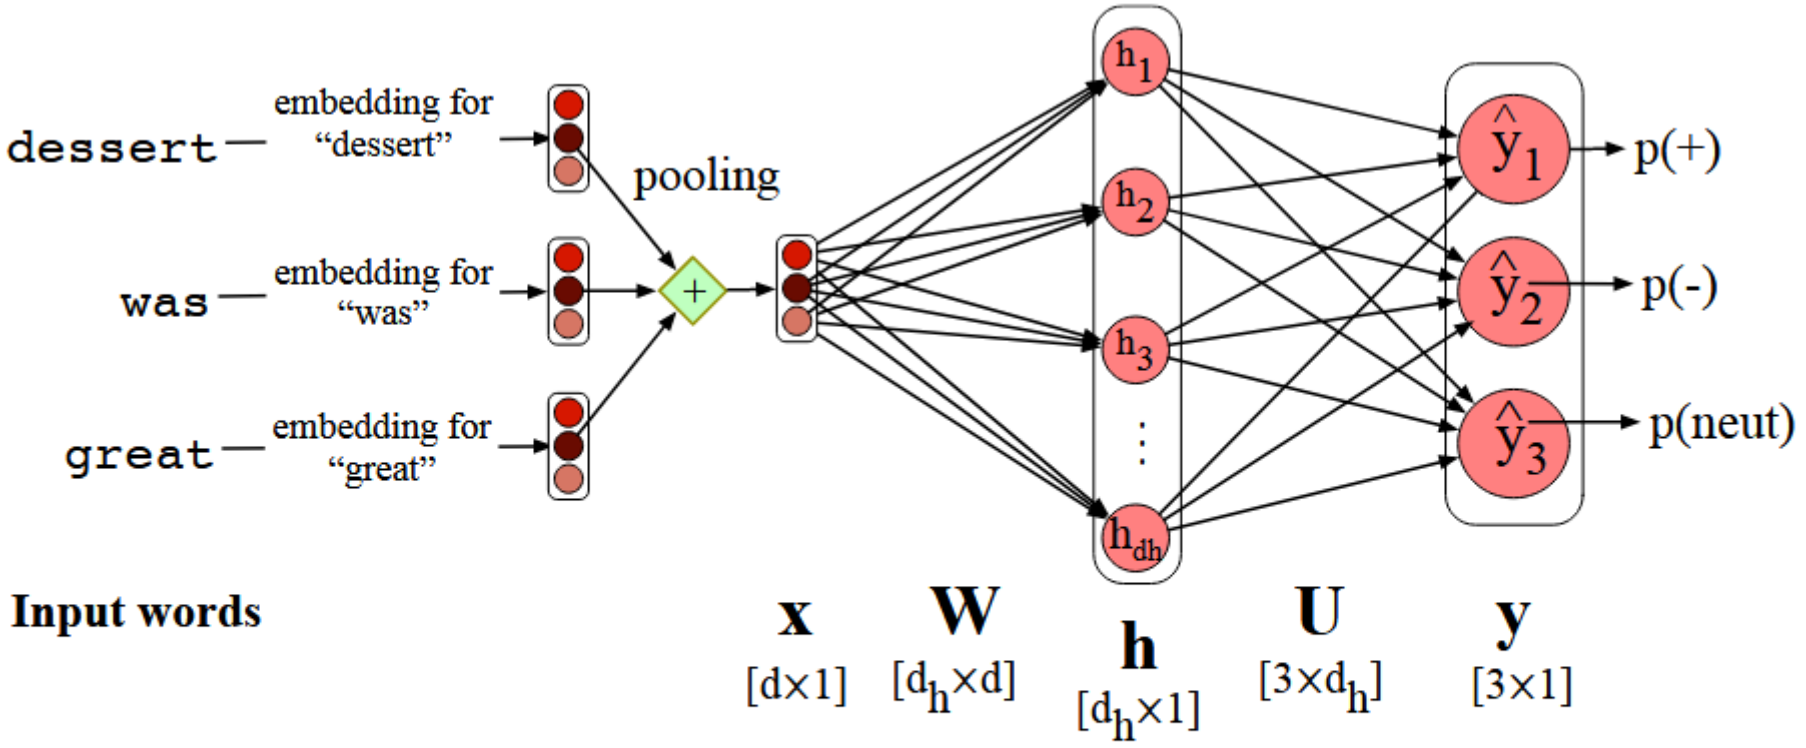

Ecuaciones de transferencia (forward):

$$\mathbf{x} = \text{mean}(\mathbf{e}(w_1), \mathbf{e}(w_2), \ldots, \mathbf{e}(w_n))$$

$$\mathbf{h} = \sigma(\mathbf{W}\mathbf{x} + \mathbf{b})$$

$$\mathbf{z} = \mathbf{U}\mathbf{h}$$

$$\hat{\mathbf{y}} = \text{softmax}(\mathbf{z})$$

- SUBWORDS, FASTTEXT -

Subwords

Las palabras se representan por un **char *n*-grams**:

Ej.: *n* = 3, where → <wh, whe, her, ere, re>, <where>

Sea $\mathcal{G}_w \subset \{1, \ldots, G\}$ el conjunto de char *n*-grams de la palabra *w.* En FastText, cada *n*-gram tiene un vector $\mathbf{z}_g$ que lo representa.

Una palabra se representa como la **suma** de los vectores $\mathbf{z}_g$, en $\mathcal{G}_w \subset \{1, \ldots, G\}$

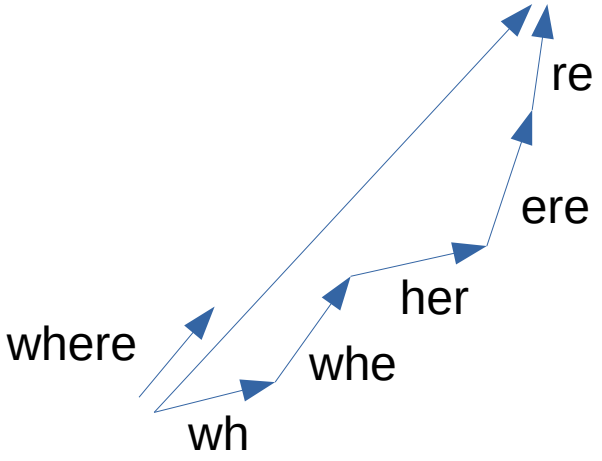

Subwords

FastText es una extensión de skip-grams basada en sub-words.

La función objetivo de skipgrams corresponde a la log verosimilitud:

$$\sum_{t=1}^{T} \sum_{c \in \mathcal{C}_t} \log p(w_c \mid w_t),$$

Podemos usar una softmax para definir la probabilidad de una palabra de contexto:

$$p(w_c \mid w_t) = \frac{e^{s(w_t,\, w_c)}}{\sum_{j=1}^{W} e^{s(w_t,\, j)}}.$$

Las palabras de contexto son ejemplos positivos. Usamos negative sampling para que el problema sea de clasificación binaria.

Bojanovski et al. (2016) Enriching Word Vectors with Subword Information, https://arxiv.org/pdf/1607.04606.pdf

Subwords

Cuando consideramos *negative sampling*, la función objetivo de clasificación binaria corresponde a una *log* loss:

$$\log\left(1 + e^{-s(w_t,\, w_c)}\right) + \sum_{n \in \mathcal{N}_{t,c}} \log\left(1 + e^{s(w_t,\, n)}\right)$$

↳ Negative samples (fuera del contexto de w_t)

Subwords

Cuando consideramos *negative sampling*, la función objetivo de clasificación binaria corresponde a una *log* loss:

$$\log\left(1+e^{-s(w_t,\,w_c)}\right)+\sum_{n\in\mathcal{N}_{t,c}}\log\left(1+e^{s(w_t,\,n)}\right)$$

↳ Negative samples (fuera del contexto de w_t)

Luego, tenemos varios problemas de clasificación binaria independientes que superponemos durante el entrenamiento:

$$\sum_{t=1}^{T}\left[\sum_{c\in\mathcal{C}_t}\ell(s(w_t,\,w_c))+\sum_{n\in\mathcal{N}_{t,c}}\ell(-s(w_t,\,n))\right]$$

donde: $\ell : x \mapsto \log(1+e^{-x})$

Subwords

x → ~ 0 → e^{0} → ~ 0 (mínima pérdida)

Log loss:

$$\log\left(1+e^{-s(w_t,\,w_c)}\right)+\sum_{n\in\mathcal{N}_{t,c}}\log\left(1+e^{s(w_t,\,n)}\right)$$

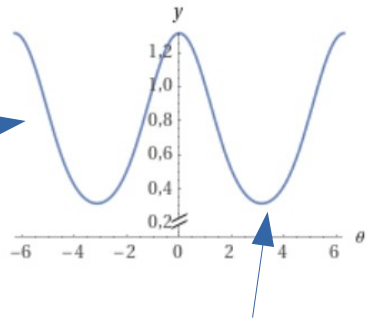

pi/2

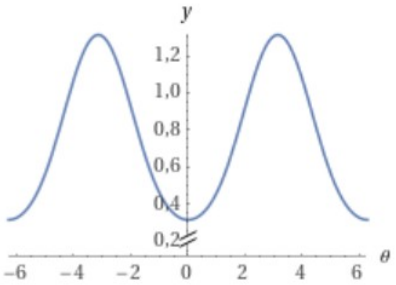

x → ~ 1 → e^{-1} → ~ 0 (mínima pérdida)

Subwords

x → ~ 0 → e^{0} → ~ 0 (mínima pérdida)

Log loss:

$$\log\left(1+e^{-s(w_t,\,w_c)}\right)+\sum_{n\in\mathcal{N}_{t,c}}\log\left(1+e^{s(w_t,\,n)}\right)$$

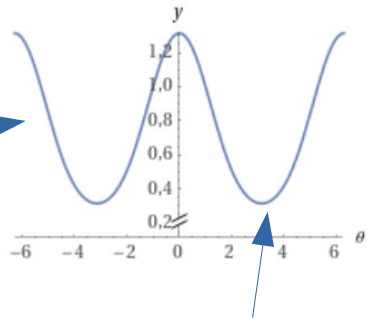

pi/2

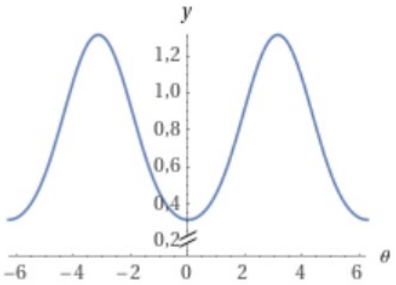

x → ~ 1 → e^{-1} → ~ 0 (mínima pérdida)

FastText se entrena usando como función de scoring:

$$s(w,c)=\sum_{g\in\mathcal{G}_w}\mathbf{z}_g^{\top}\mathbf{v}_c.$$

Entrenamiento de FastText

- Se entrenó en base a la implementación en C de skipgram y CBOW del word2vec package de Google.

- Optimización: SGD con linear decay.

- Dims de embeddings: 300; Por cada + ex. 5 – exs at random (según curva de frecuencia); ventana de contexto = 5.

- Implementación del modelo en https://github.com/facebookresearch/fastText

- Data provenance: Wikipedia dumps (https://dumps.wikimedia.org/), original en 9 idiomas (incluído el español), versión posterior con ~140 idiomas.

FastText (notas importantes)

- FastText es rápido en entrenamiento (1B tokens ~ 10 mins in CPU).

- La librería proporciona vectores de palabras pero si hay OOV usa los n-grams para calcular el nuevo vector.

- FastText es invariante al orden de los tokens (BOW).

- FastText es independiente del contexto (vectores estáticos).

- MODELO DE LENGUAJE NEURONAL -

Modelo de lenguaje neuronal

Un modelo de lenguaje neuronal aprende las transiciones entre palabras a partir de un corpus. Se basa en una secuencia de tokens precedentes de tamaño fijo (N):

$$P(w_t|w_1,\ldots,w_{t-1}) \approx P(w_t|w_{t-N+1},\ldots,w_{t-1})$$

Lo que queremos es que el modelo aprenda la distribución condicionada a la secuencia de entrada. Una forma de hacerlo es esta:

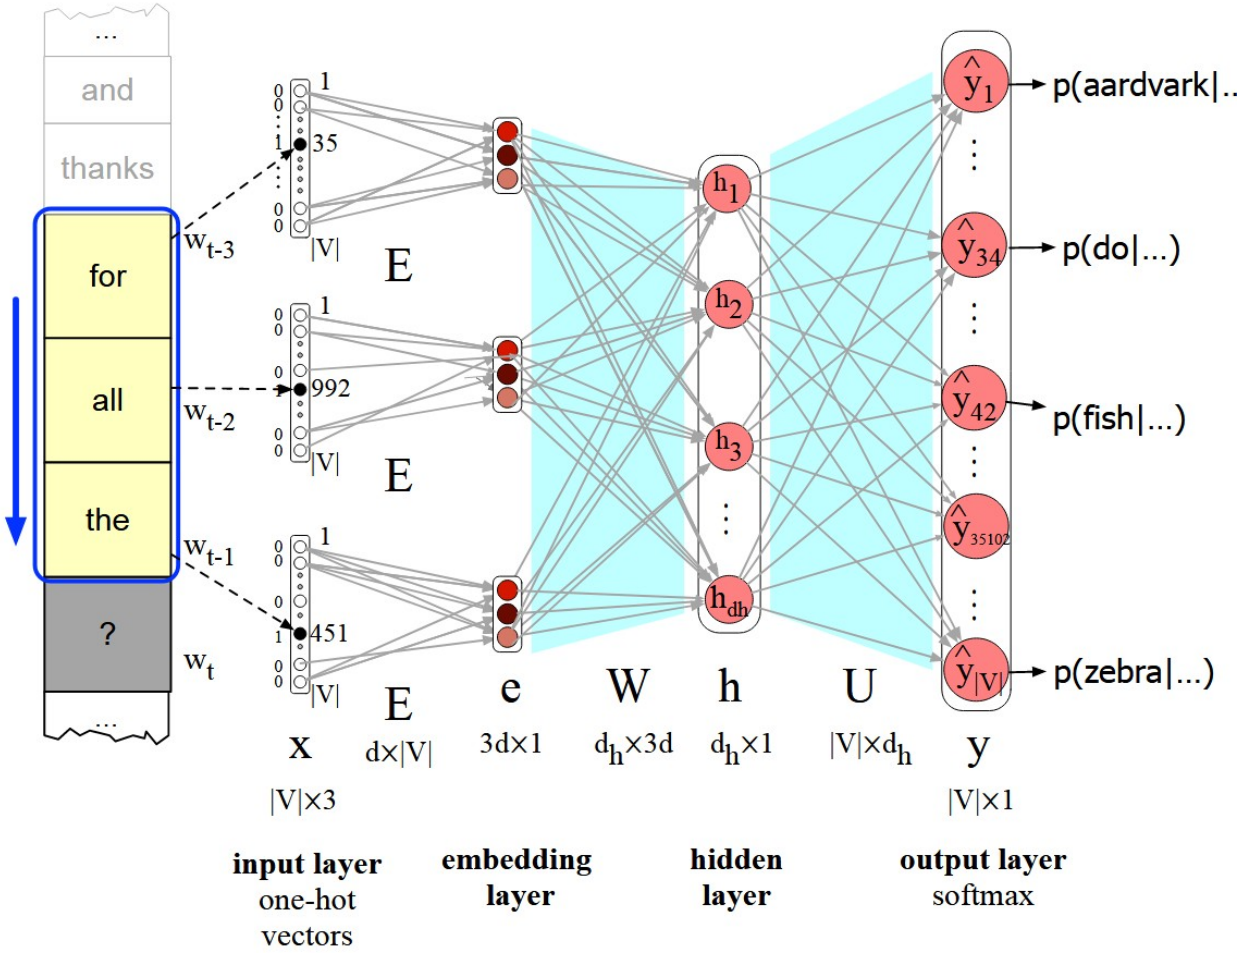

Modelo de lenguaje neuronal

Las ecuaciones de forward para la red son:

$$\begin{aligned}
\mathbf{e} &= [\mathbf{E}\mathbf{x}_{\mathbf{t}-3}; \mathbf{E}\mathbf{x}_{\mathbf{t}-2}; \mathbf{E}\mathbf{x}_{\mathbf{t}-1}] \\
\mathbf{h} &= \sigma(\mathbf{W}\mathbf{e} + \mathbf{b}) \\
\mathbf{z} &= \mathbf{U}\mathbf{h} \\
\hat{\mathbf{y}} &= \text{softmax}(\mathbf{z})
\end{aligned}$$

Para entrenar la red usamos los gradientes de una palabra conocida, la siguiente que ocurre en el texto, en base a una ventana deslizante de largo *n* tokens:

$$\theta^{s+1} = \theta^{s} - \eta \frac{\partial \left[-\log p(w_t | w_{t-1}, \ldots, w_{t-n+1}) \right]}{\partial \theta}$$

donde los parámetros de la red son: $\theta = \mathbf{E}, \mathbf{W}, \mathbf{U}, \mathbf{b}.$

Modelo de lenguaje neuronal con auto-supervisión

La idea de entrenar la red con un esquema de auto-supervisión es clave, ya que permite crecer en el tamaño del corpus sin involucrar esfuerzo de anotación humano: