

IIC3670 Procesamiento de Lenguaje Natural

https://github.com/marcelomendoza/IIC3670

- POS, NER Y SEQUENCE LABELING -

POS tagging

- Etiquetar cada término de acuerdo a la función que este cumple en el texto.
- Puede ayudarnos en tareas como detección de estilo, parsing, detección de colocaciones.
- Tarea importante en NLP.



POS tagging

	Tag	Description	Example
Open Class	ADJ	Adjective: noun modifiers describing properties	red, young, awesome
	ADV	Adverb: verb modifiers of time, place, manner	very, slowly, home, yesterday
	NOUN	words for persons, places, things, etc.	algorithm, cat, mango, beauty
	VERB	words for actions and processes	draw, provide, go
	PROPN	Proper noun: name of a person, organization, place, etc	Regina, IBM, Colorado
	INTJ	Interjection: exclamation, greeting, yes/no response, etc.	oh, um, yes, hello
Closed Class Words	ADP	Adposition (Preposition/Postposition): marks a noun's	in, on, by under
		spacial, temporal, or other relation	
	AUX	Auxiliary: helping verb marking tense, aspect, mood, etc.,	can, may, should, are
	CCONJ	Coordinating Conjunction: joins two phrases/clauses	and, or, but
	DET	Determiner: marks noun phrase properties	a, an, the, this
C C	NUM	Numeral	one, two, first, second
Se	PART	Particle: a preposition-like form used together with a verb	up, down, on, off, in, out, at, by
Clo	PRON	Pronoun: a shorthand for referring to an entity or event	she, who, I, others
	SCONJ	Subordinating Conjunction: joins a main clause with a subordinate clause such as a sentential complement	that, which
Other	PUNCT		; , ()
	SYM	Symbols like \$ or emoji	\$, %
0	X	Other	asdf, qwfg

POS tagging en NLTK

```
>>> text = word_tokenize("And now for something completely different")
>>> nltk.pos_tag(text)
[('And', 'CC'), ('now', 'RB'), ('for', 'IN'), ('something', 'NN'),
('completely', 'RB'), ('different', 'JJ')]
```

```
>>> text = word_tokenize("They refuse to permit us to obtain the refuse permit")
>>> nltk.pos_tag(text)
[('They', 'PRP'), ('refuse', 'VBP'), ('to', 'TO'), ('permit', 'VB'), ('us', 'PRP'),
('to', 'TO'), ('obtain', 'VB'), ('the', 'DT'), ('refuse', 'NN'), ('permit', 'NN')]
```

POS tagging en Spacy (Español)

```
!python -m spacy download es_core_news_sm
!python -m spacy download es_core_news_md
```

```
Un | Un | DET

desastroso | desastroso | NOUN

espirítu | espirítu | PROPN

posee | poseer | VERB

tu | tu | DET

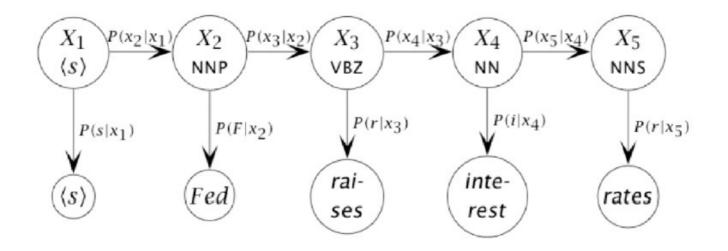
tierra | tierra | NOUN

: | : | PUNCT
```

POS tagging con Hidden Markov Models (modelo clásico)

- Se dispone de un corpus etiquetado.
- La secuencia de tags es interpretada como una cadena de Markov: $P(x_{t+1} \mid x_t, ..., x_1) = P(x_{t+1} \mid x_t), x_1, ..., x_{t+1}$ representan tags
- ▶ Usamos un modelo generativo para términos, con tags como estados ocultos: $P(t \mid x_1, ..., x_{t+1}) = P(t \mid x_{t+1})$

POS tagging con HMM (modelo clásico)



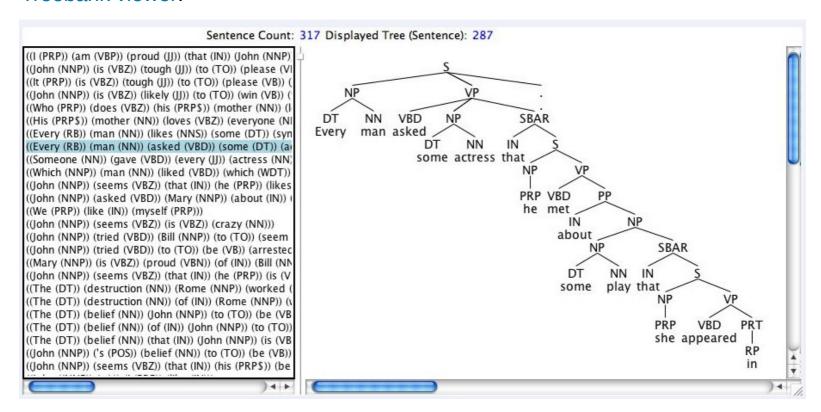
► En general muestran buena precisión (sobre 90 %).

El algoritmo de entrenamiento se llama Viterbi.

POS tagging ¿Cuáles datos usan?

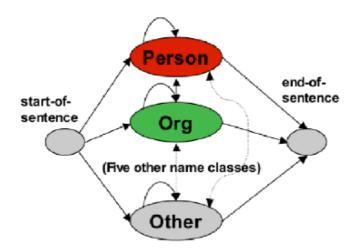
Treebanks: Penn treebank (más famoso), UAM Spanish Treebank, ...

Treebank viewer:



Named Entity Recognition (NER)

- ► Tarea: Identificar entidades en texto (personas, organizaciones, etc.)
- Separa el text en chunks, y para cada cual asocia una NE. Opera sobre texto tagged.
- ► NER types: organization, person, location, date, time, money, percent, facility (human made artifacts), gpe (geo-political ents).
- ▶ POS tagging puede ayudar, agregando entity como un estado mas.



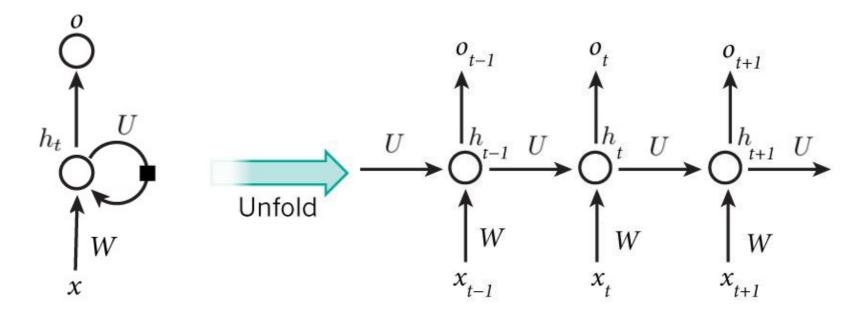


Named Entity Recognition puede ser muy desafiante:

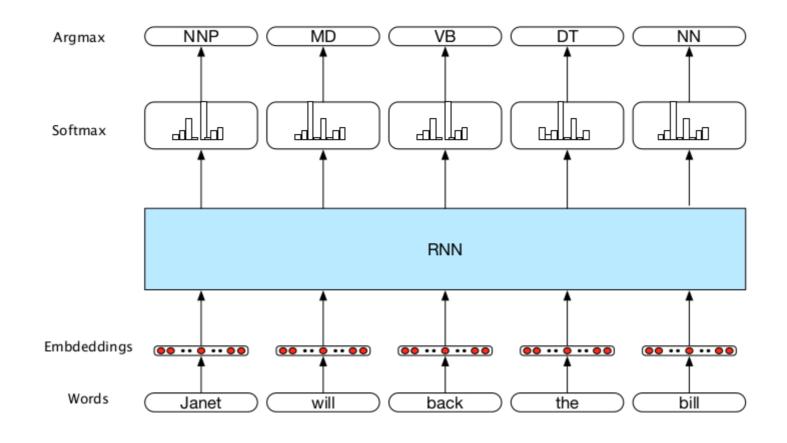


Presentamos los datos como secuencia: $X=(x_1,x_2,\ldots,x_T)$

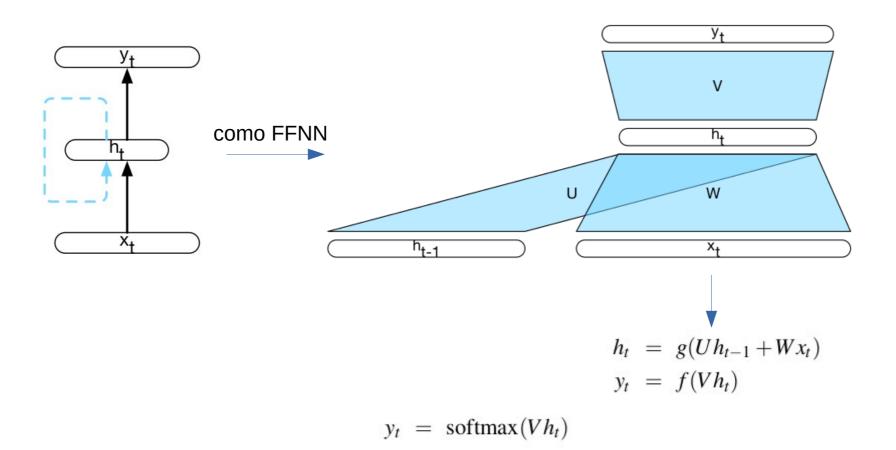
Recurrente convencional: $h_t = g(W \cdot x_t + U \cdot h_{t-1})$



Red recurrente (sequence labeling):

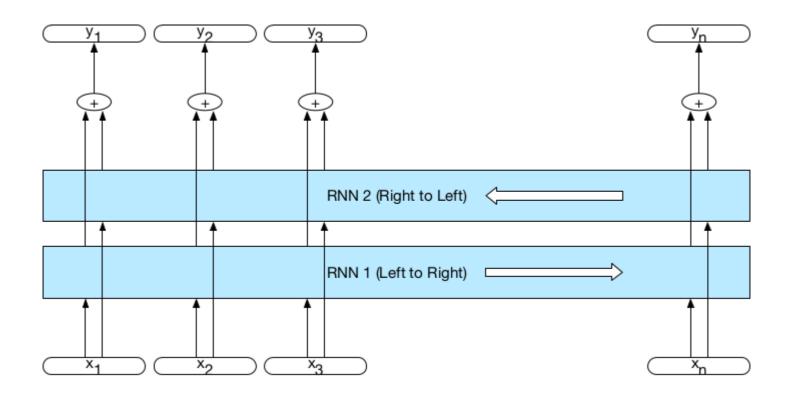


Red recurrente:

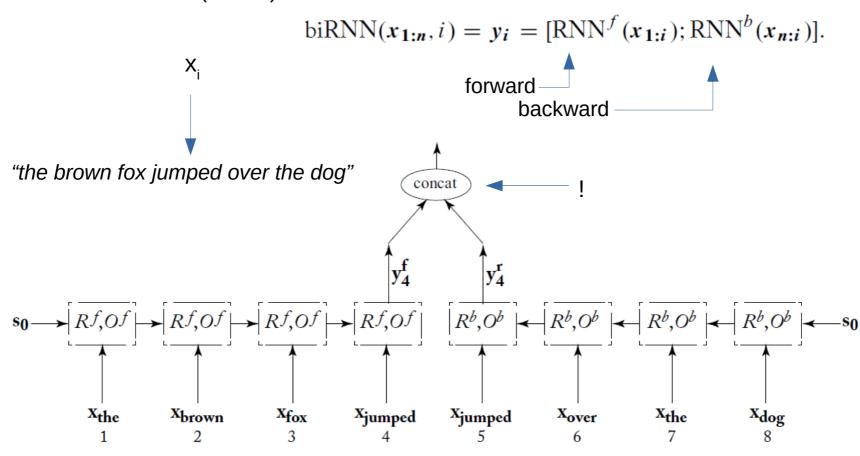


- UC - M. Mendoza -

Bidirectional RNN (biRNN):



Bidirectional RNN (biRNN):

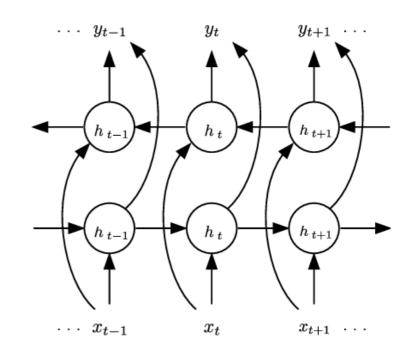


Bidirectional RNN (biRNN):

$$h_t^{(f)} = g(W^{(f)} \cdot x_t + U^{(f)} \cdot h_{t-1}^{(f)})$$

$$h_t^{(b)} = g(W^{(b)} \cdot x_t + U^{(b)} \cdot h_{t+1}^{(b)})$$

$$y_t = g(V^{(f)} \cdot h_t^{(f)} + V^{(b)} \cdot h_t^{(b)})$$



Bidirectional RNN para POS tagging con modelo preentrenado de subpalabras

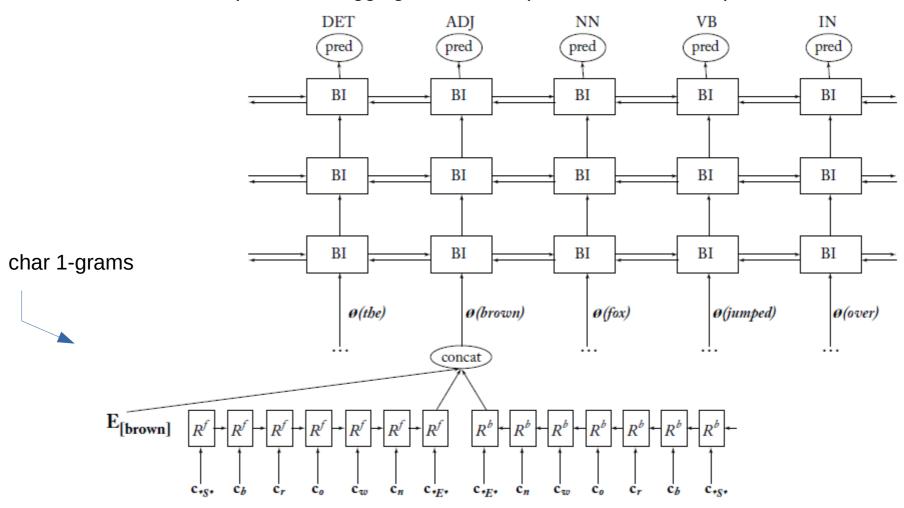
Char embeddings:
$$x_i = \phi(s, i) = [E_{[w_i]}; \text{RNN}^f(c_{1:\ell}); \text{RNN}^b(c_{\ell:1})].$$

FastText

char n-grams

POS-tagging:
$$p(t_i = j | w_1, ..., w_n) = \text{softmax}(\text{MLP}(\text{biRNN}(x_{1:n}, i)))_{[j]}$$

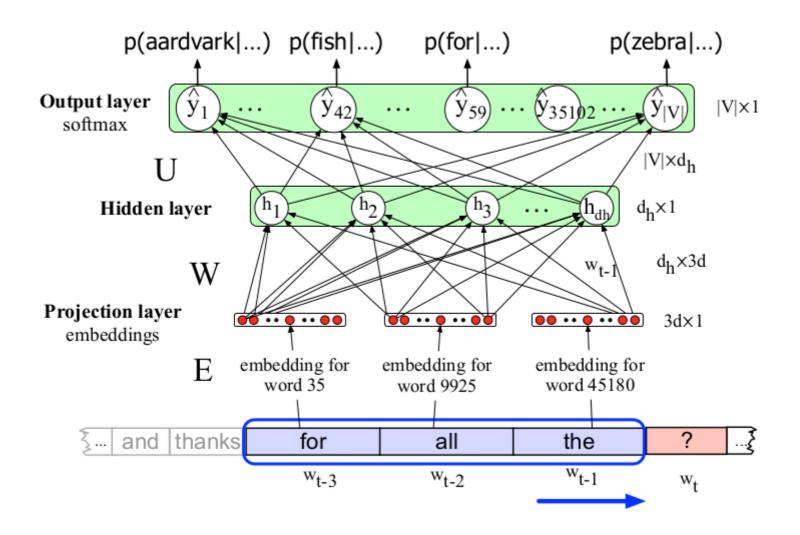
Bidirectional RNN para POS tagging con modelo preentrenado de subpalabras

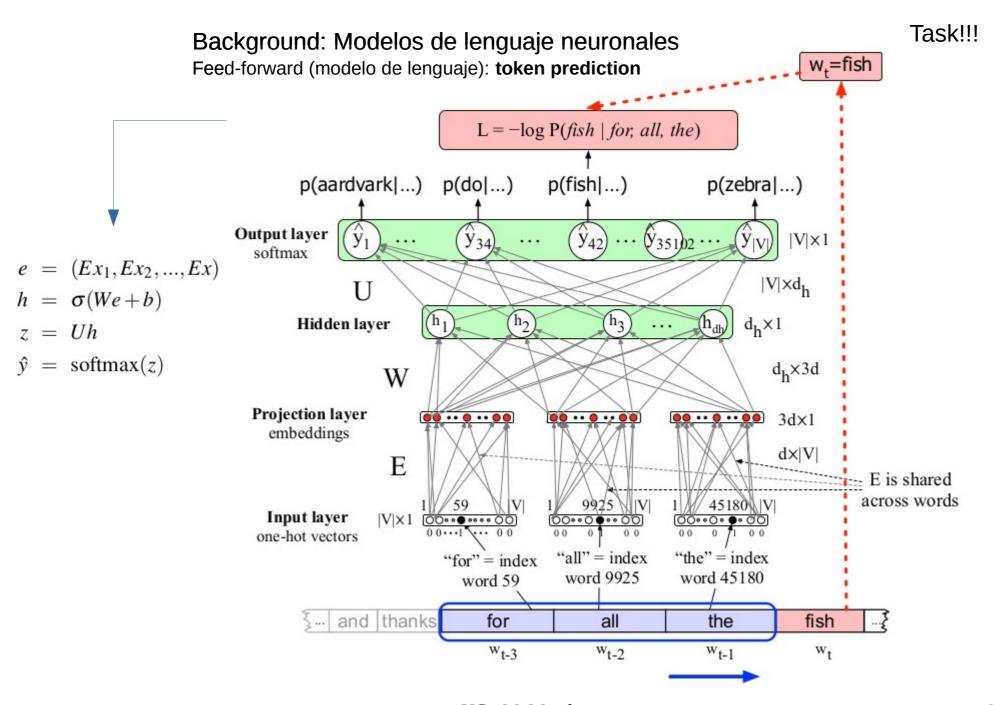


- MODELOS DE LENGUAJE -

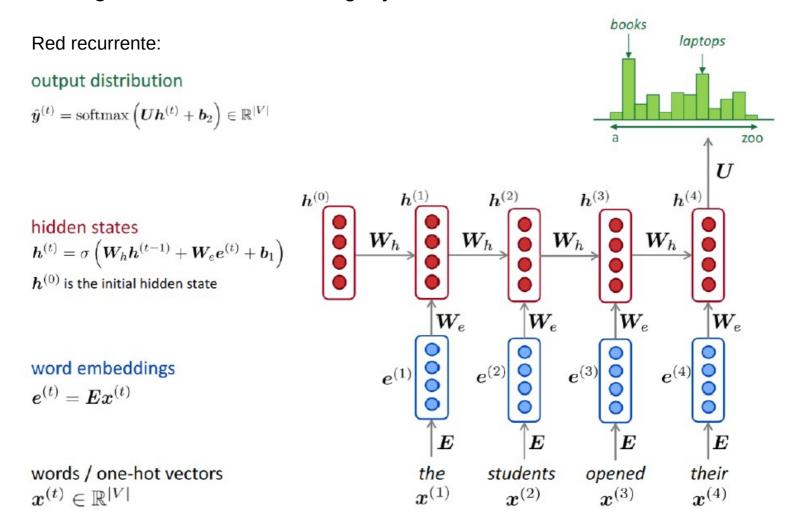
Background: Modelos de lenguaje neuronales

Feed-forward (modelo de lenguaje): token prediction





Background: Modelos de lenguaje neuronales



Bengio, Y., Ducharme, R., Vincent, P., Jauvin, C. A Neural Probabilistic Language Model. Journal of Machine Learning Research 3:1137-1155, 2003.

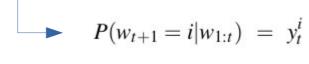
Background: Modelos de lenguaje neuronales

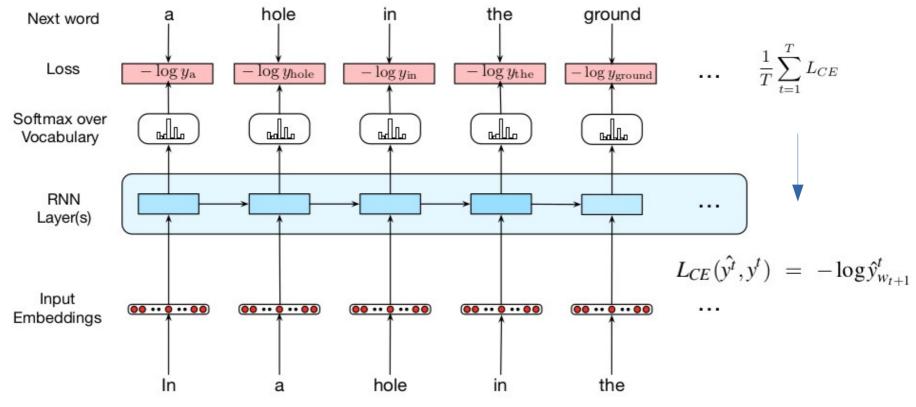
Red recurrente:

$$e_t = E^T x_t$$

 $h_t = g(Uh_{t-1} + We_t)$
 $y_t = \text{softmax}(Vh_t)$

Entrenamiento auto-regresivo:



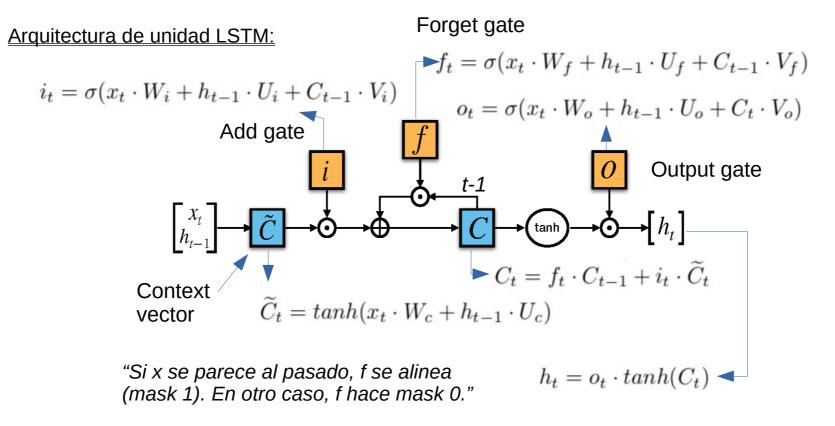


- DEPENDENCIA DEL CONTEXTO -

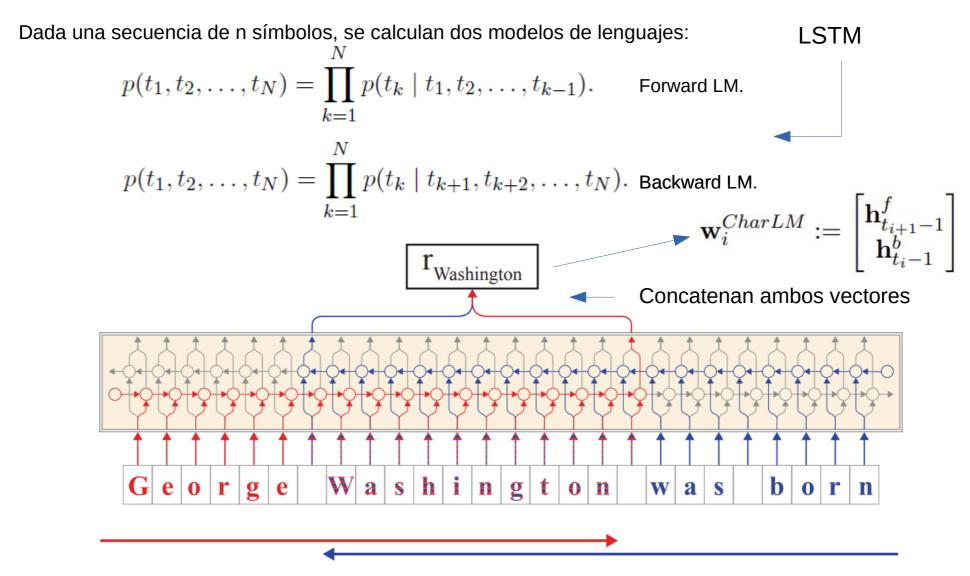
Extensión a LSTM

<u>Long-short term memory (LSTM)</u>: dividen el problema en dos sub-problemas: a) remover información innecesaria, b) agregar información necesaria para resolver una tarea.

Las LSTM hacen lo anterior agregando unidades de control de flujo de información. Cada unidad consiste de una capa FF seguida por una sigmoid (activación). Combinando la salida de la sigmoid con productos, se obtiene un efecto similar al de una máscara binaria.

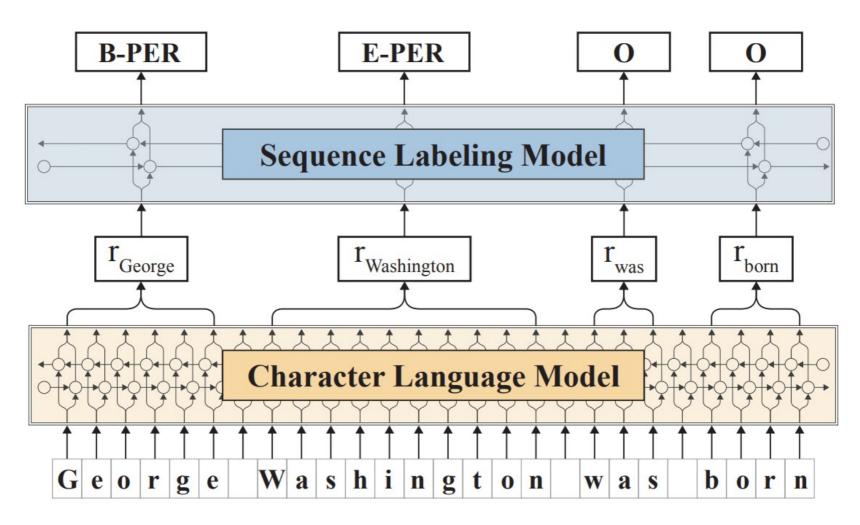


FLAIR



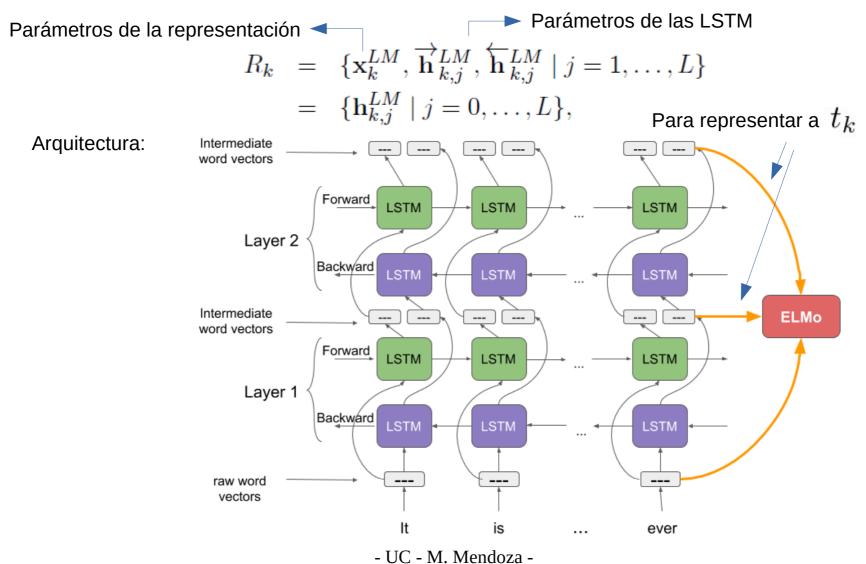
FLAIR

Luego usan los string embeddings en NER:



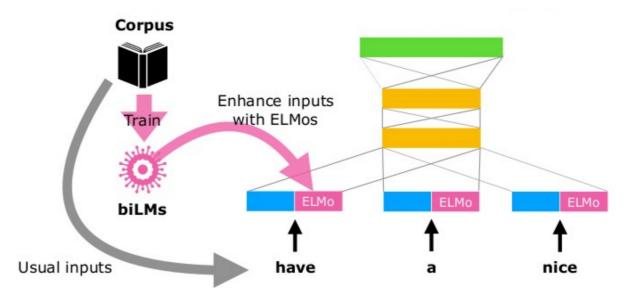
Embeddings basados en modelos de lenguaje (ELMo)

Idea similar a FLAIR pero con multicapa y modelos basados en palabras:



Embeddings basados en modelos de lenguaje (ELMo)

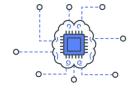
ELMo: se puede combinar con otras representaciones según la tarea específica:



El modelo final de ELMo (pre-entrenado) usa dos capas LSTM con vectores de dimensionalidad 512. Para la capa de representación, ELMo usa char n-grams y una capa de proyección de dimensionalidad 512.

ELMo fue entrenado sobre el 1 Billion Word Benchmark.

Fine tuning para downstream tasks implica disminución en perplexity y mejoras en desempeño.





Ciprian Chelba, Tomas Mikolov, Mike Schuster, Qi Ge, Thorsten Brants, Phillipp Koehn, and Tony Robin-son. 2014. One billion word benchmark for measuring progress in statistical language modeling. In INTERSPEECH.