



PONTIFICIA
UNIVERSIDAD
CATÓLICA
DE CHILE

Procesamiento de Lenguaje Natural

github.com/marcelomendoza/IIC3670

Marcelo Mendoza

El vector de una pieza lo arma su contexto

La atención mezcla cada posición con todas las demás, así que la salida de una pieza es función de la frase entera.

$$z_i^{(\ell)} = \sum_{j=1}^n \alpha_{ij} v_j^{(\ell-1)}$$


la suma recorre todas las posiciones

$$z_i^{(\ell)} = f(\mathbf{x}_1, \dots, \mathbf{x}_n)$$

así que depende de la frase entera, no de x_i

$$z_i = z_i^{(L)}$$

y se repite en las L capas, una sobre otra



En rojo, dos sentidos distintos

El sentido financiero contra el de orilla de río.

En gris, el mismo sentido en otra frase

Si esta también cayera, la caída sería del modelo y no del contexto.

Lo que separa es el sentido

La gris se queda en 0,88 y la roja baja a 0,40.

Medido sobre bert-base-uncased, con «bank» en el mismo índice de las tres frases.


Masked language model

Se tapa una parte de la entrada y se le pide al modelo que la reconstruya. El texto sin anotar alcanza, porque la respuesta es lo que se tapó.

$\tilde{x}_i = [\text{MASKED}]$ si $i \in M$ M es una fracción de las posiciones

$h = \text{Encoder}(\tilde{x}_1, \dots, \tilde{x}_n)$ con atención global, sin restricción

$\mathcal{L} = - \sum_{i \in M} \log P(x_i | \tilde{x})$ solo puntúan las posiciones tapadas



Se tapa el contenido

El placeholder permanece en la secuencia y las demás posiciones lo atienden.

Solo puntúan los tapados

Las demás salidas se calculan igual.

Pide las dos direcciones

Lo que resuelve el placeholder suele estar a la derecha.

Qué se pone en el placeholder

No siempre el símbolo. Una de cada cinco veces se pone otra cosa, y la razón es que el símbolo no existe cuando el modelo se usa.

$$\mathbf{M} \subset \{1, \dots, n\}, \quad |\mathbf{M}| = 0,15 n$$


se sortea el 15 % de las posiciones

$$\tilde{x}_i = \begin{cases} [\text{MASK}] & \text{con prob. } 0,8 \\ w \sim \mathcal{V} & \text{con prob. } 0,1 \\ x_i & \text{con prob. } 0,1 \end{cases}$$

$i \in \mathbf{M}$; $[\text{MASK}]$ no existe al usar el modelo

$$\mathcal{L} = - \sum_{i \in \mathbf{M}} \log P(x_i \mid \tilde{x})$$

y se puntúa sobre x_i en los tres casos



Devlin et al., NAACL 2019.

El símbolo solo existe al entrenar

Después no aparece nunca, y el modelo no debe depender de él.

Por eso una parte va con ruido

Una palabra cualquiera, o la original sin tocar.

La pérdida no cambia


En los tres casos se pide la palabra que estaba.

Lo que el modelo predice


Las tres frases son idénticas hasta el placeholder. Lo único que cambia está después, y cambia la respuesta entera.

she went to the [MASK] to ...

... withdraw some money



... watch the sunset



... borrow a novel



0.0 0.2 0.4 0.6 0.8 1.0 1.2

probabilidad que el modelo le da a la pieza

bert-base-uncased, sin ajustar nada. Las cuatro piezas más probables de cada frase.

Next sentence prediction

La segunda tarea es decidir si la segunda oración seguía a la primera en el texto. La mitad de los ejemplos se arma con la continuación real y la mitad con una oración cualquiera del corpus.

$$e_i = E_{x_i}^{\text{tok}} + \mathbf{E}_{s_i}^{\text{seg}} + E_i^{\text{pos}}$$

$s_i \in \{A, B\}$: dos filas

$$P(y \mid \cdot) = \text{softmax}(W z_{[\text{CLS}]}) , \quad y \in \{\text{IsNext}, \text{NotNext}\}$$

colgado de [CLS]

$$\mathcal{L} = \mathcal{L}_{\text{MLM}} + \mathcal{L}_{\text{NSP}}$$

sin peso entre ellas

una sola secuencia con las dos oraciones

[CLS] the dog chased the cat . [SEP] it climbed a tree . [SEP]
A A A A A A A A B B B B B B

a qué segmento pertenece cada pieza

y la segunda oración se sortea al armar cada ejemplo

50 %	la continuación real	IsNext	1,0000
	«it climbed a tree»		
50 %	una oración cualquiera del corpus	NotNext	0,0093
	«revenue rose twelve percent»		

La entrada suma tres tablas

Pieza, segmento y posición. La de segmento tiene dos filas.

El cabezal cuelga de [CLS]

Sin contenido propio, pero atiende a todas, así que resume la secuencia.

Las dos pérdidas se suman sin peso

El mismo encoder tiene que resolver las dos tareas.

Devlin et al., NAACL 2019. Puntajes medidos con el cabezal de NSP de bert-base-uncased.

WordPiece parte el texto a la entrada

Antes de la primera capa, cada palabra se convierte en piezas del vocabulario. El algoritmo que decide dónde cortar es de 2012.



Schuster y Nakajima, ICASSP 2012; Sennrich, Haddow y Birch, ACL 2016; Wu et al., 2016; Devlin et al., NAACL 2019.

Cómo se parte la palabra

BPE compone la palabra de abajo hacia arriba. WordPiece consulta una tabla de hashing y se queda con la pieza más larga que calce.

BPE : aplicar las fusiones en el orden aprendido

WordPiece : la pieza más larga que calce, de izquierda a derecha

si nada calza $\Rightarrow$ [UNK], la palabra entera

desestabilización

WordPiece toma la pieza más larga que calce

des ##est ##ab ##iliz ##ación

BPE repite las fusiones en el orden aprendido

d e s e s t a b i l i z a c i ó n · se parte de las letras

d e s e s t a b i l i z a c i ó n · tras 7 fusiones

des estab il ización · hasta que no calza ninguna

· es la marca de fin de palabra de la clase 5

en BERT: Straße $\rightarrow$ st ##raße Ijsselmeer $\rightarrow$ [UNK]

un carácter que falta descarta la palabra entera, no solo ese carácter

BPE compone bottom-up

Desde las letras, aplicando sus fusiones en orden.

WordPiece consulta un hash

Prueba prefijos contra el vocabulario, sin componer nada.

La falla de WordPiece

Un carácter que no esté descarta la palabra entera.

La misma tabla, dos reglas

Un solo vocabulario, segmentado de las dos formas. Lo único distinto entre las dos columnas es la regla con que se recorre la palabra.

	BPE repitiendo las fusiones	WordPiece la pieza más larga que calce
consejeros	conse ##jeros	consejero ##s
Premios	Prem ##ios	Premio ##s
llegara	lleg ##ara	llegar ##a
materializando	materi ##aliz ##ando	materia ##l ##iza ##n ##do
suspensión	sus ##p ##ensión	sus ##pe ##n ##s ##ión
vanguardia	van ##gu ##ardia	van ##gua ##r ##di ##a

avanza avara desde la izquierda, así que un prefijo largo puede dejar un sufijo que no calza

antigüedad	anti ##g ##ü ##edad	[UNK]
------------	---------------------	-------

el sufijo trae un carácter que el vocabulario no tiene, y BPE conserva el resto mientras WordPiece descarta la palabra entera

Vocabulario de 4.000 fusiones sobre conll2002 esp.train, medido en esp.testb sobre las palabras alfabéticas.

STS-B

El conjunto con el que se mide la similitud entre oraciones. Cada par lleva un puntaje anotado por personas, de 0 a 5.

la escala del anotador

- 5 significan lo mismo
- 4 salvo detalles menores
- 3 falta información importante
- 2 comparten algún detalle
- 1 solo el mismo tema
- 0 sin relación

cuatro pares, con su puntaje

- 5,00 A man with a hard hat is dancing.
A man wearing a hard hat is dancing.
- 3,60 A person is peeling shrimp.
A person is preparing shrimp.
- 2,38 A man is cutting up a potato.
A man is cutting up carrots.
- 0,00 The man is riding a horse.
A woman is using a hoe.

cinco personas anotan cada par en Mechanical Turk y el puntaje publicado es el promedio de las cinco
los pares salen de titulares, subtítulos de imágenes y foros, reunidos entre 2012 y 2017

Sentence-BERT

Un codificador de oraciones. Cada oración se codifica por separado en un embedding de tamaño fijo, y la similitud es el coseno entre dos embeddings.

$$\mathbf{u} = \text{pool}(\text{Encoder}(A))$$


una frase entra sola y sale su vector

$$\text{sim} = \cos(\mathbf{u}, \mathbf{v})$$

comparar es un coseno entre dos de esos

$$\mathbf{o} = \text{softmax}(W [u; v; |u - v|])$$

solo al ajustar; después W se descarta



Una oración, un embedding

Se codifica sin par y sin depender de ninguna otra.

El pooling es el promedio

Sobre las salidas del encoder, no el vector de [CLS].

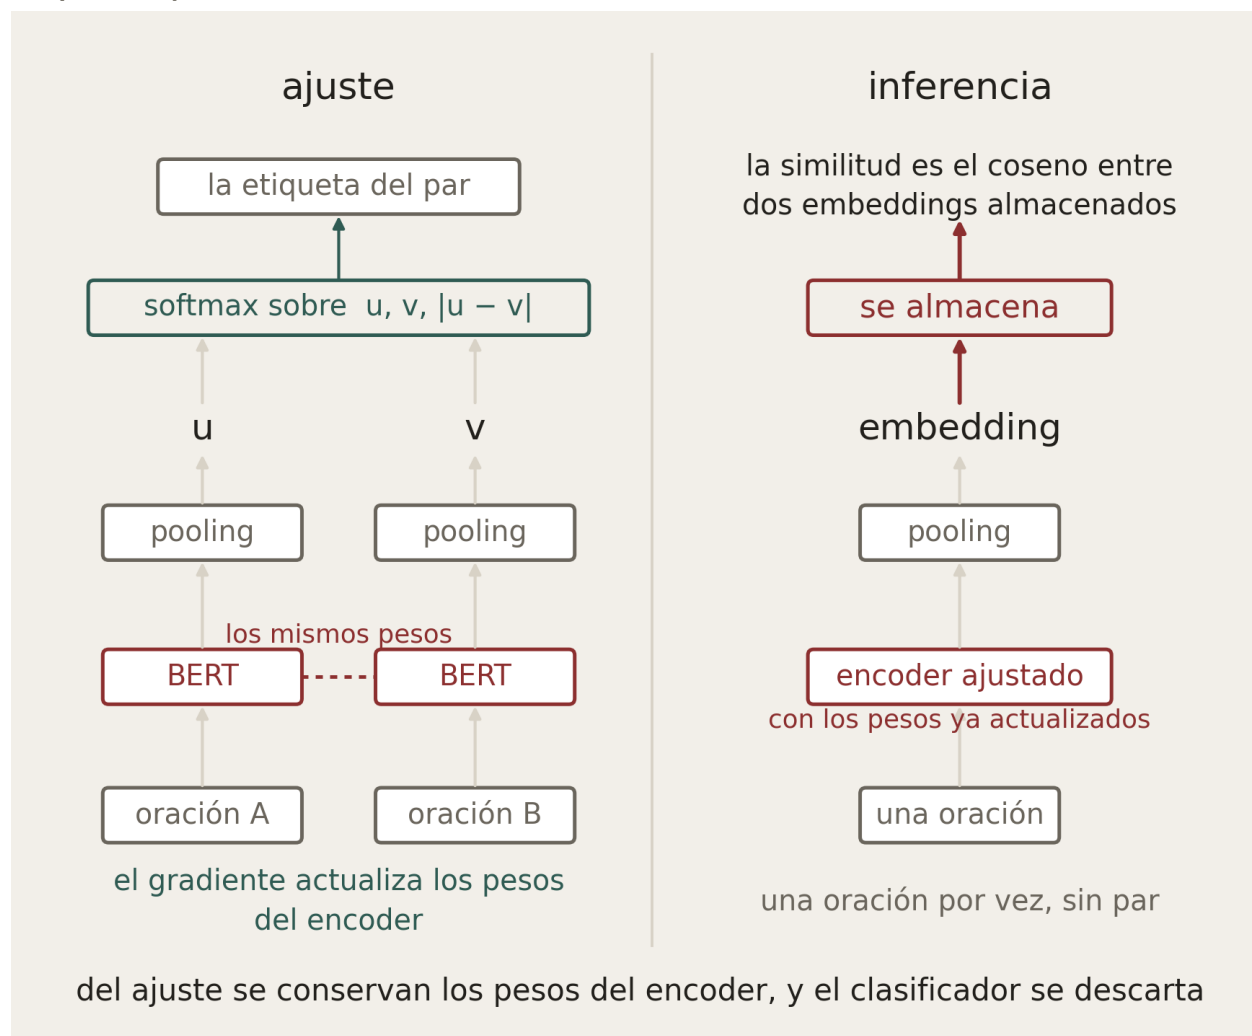
Lo que cambia es el encoder ajustado

El mismo montaje sin ajustar se queda en 59,3.

Reimers y Gurevych, EMNLP 2019. Medido sobre los 1.500 pares de validación de STS-B.

Una red siamesa

El ajuste usa dos encoders siameses, que son el mismo con los mismos pesos. En inferencia queda uno solo, con los pesos ya actualizados.



RoBERTa

La misma arquitectura que BERT, entrenada de otra manera. Sus autores concluyen que BERT estaba considerablemente subentrenado.

	BERT	RoBERTa
arquitectura	L = 12, H = 768, A = 12	la misma
tokenizador	WordPiece, 30.522	BPE por bytes, 50.265
preentrenamiento	masked LM y NSP	solo masked LM
símbolos	[CLS] y [SEP]	<s> y </s>, el mismo papel
tabla de segmentos	dos filas, A y B	no la tiene
enmascarado	fijo, decidido una vez	distinto en cada pasada
corpus	16 GB, libros y Wikipedia	160 GB, diez veces más
entrenamiento	1 M de pasos, lote 256	500 K de pasos, lote 8.000
ventana de entrada	512 piezas	512 piezas
parámetros	109,5 M base	124,6 M base, 355,4 M grande

Liu et al., 2019. Tamaños medidos sobre los modelos publicados. CLS viene de classification y SEP de separator.

Ajustar todo o solo el cabezal

El ajuste supervisado, o SFT, es entrenar con datos anotados sobre el encoder ya preentrenado. La decisión es si el encoder también se actualiza.

$$\theta = (\theta_{\text{enc}}, \mathbf{W})$$


encoder y cabezal

completo : $\nabla \mathcal{L}$ sobre $\theta_{\text{enc}}, \mathbf{W}$

se actualizan los dos

solo cabezal : $\nabla \mathcal{L}$ sobre $\mathbf{W}$

θ_{enc} congelado



El cabezal es diminuto

1.538 parámetros contra 109,5 millones del encoder.

Con el encoder congelado se pierden seis puntos

86,1 contra 92,2 de exactitud sobre SST-2.

Aun así, muy por encima del azar

Contestar siempre la clase más común da 50,9 %.

Medido con bert-base-uncased sobre SST-2, que es clasificar reseñas de cine en positiva o negativa.

Cuatro formas de usar el encoder

Las tareas con las que se evalúan los encoders caen en cuatro casillas, según si entra una secuencia o un par y si la salida es una o una por posición.

el encoder es el mismo en las cuatro; lo que cambia es de dónde se toma la salida

clasificación de secuencia

entra una secuencia

sale una etiqueta

SST-2, CoLA

sentimiento, aceptabilidad

clasificación de pares

entra un par

sale una etiqueta

MNLI, QQP, STS-B

inferencia, paráfrasis, similitud

etiquetado de secuencia

entra una secuencia

sale una por posición

CoNLL-2003

entidades nombradas

extracción de respuesta

entra un par

sale un fragmento

SQuAD

pregunta y párrafo

Clasificación de secuencia

Una etiqueta para toda la secuencia. Se toma la salida de la posición del principio y se le cuelga una capa lineal.

$$z_{[\text{CLS}]} = \text{Encoder}(x)_{[\text{CLS}]}$$

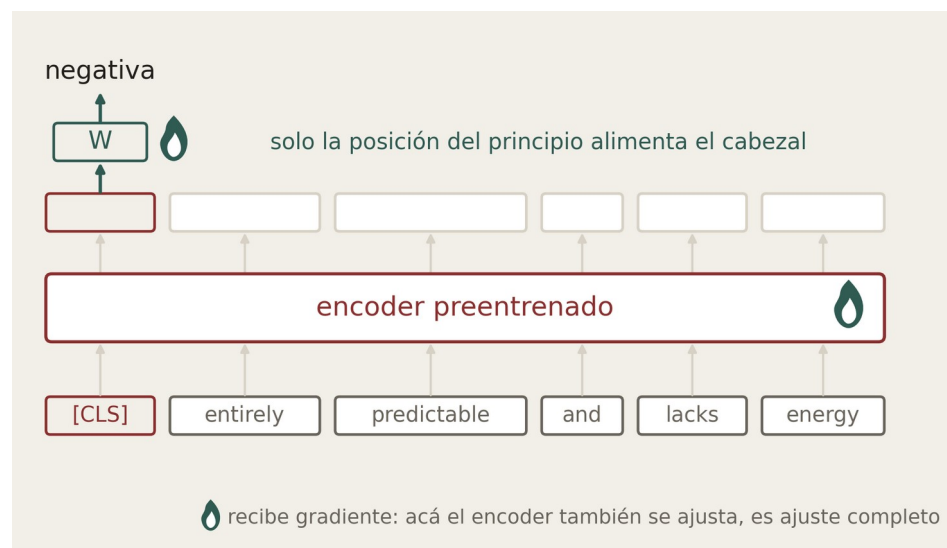
la salida de la posición del principio

$$y = \text{softmax}(W z_{[\text{CLS}]})$$

una softmax sobre K clases

$$W \in \mathbb{R}^{K \times H}$$

el cabezal completo, sin capas ocultas



Solo se usa una posición

Las demás salidas se calculan y se descartan.

El cabezal es una matriz

De K por H , sin capas ocultas ni activaciones.

Y el encoder se ajusta con él

El cabezal solo proyecta; el trabajo lo hace el encoder.

Etiquetado de secuencia

Una etiqueta por posición. El mismo cabezal se aplica a todas las salidas, y la etiqueta de una palabra sale de su primera pieza.

$$z_1, \dots, z_n = \text{Encoder}(x)$$


una salida por posición

$$y_i = \text{softmax}(W z_i)$$

el mismo W en toda posición

$$y_{\text{palabra}} = y_{\text{primera pieza}}$$

las de continuación no puntúan



Ahora se usan todas las salidas

Y el cabezal es compartido entre posiciones.

Las piezas obligan a alinear

La convención es tomar la primera de cada palabra.

Y el encoder se ajusta con él

Sin eso, el contexto de la salida no sería el de la tarea.

Extracción de respuesta

La respuesta no se genera, se señala. El cabezal es mínimo, y por eso la tarea solo funciona ajustando el encoder junto con él.

$$\mathbf{W} \in \mathbb{R}^{2 \times H}, \quad \mathbf{s} = \mathbf{W}_1, \quad \mathbf{e} = \mathbf{W}_2$$

el cabezal es esa matriz

$$P_{\text{ini}}(i) = \text{softmax}_i(\mathbf{s} \cdot \mathbf{z}_i)$$


la pregunta entra por $\mathbf{z}_i$

$$P_{\text{fin}}(j) = \text{softmax}_j(\mathbf{e} \cdot \mathbf{z}_j)$$

no por $\mathbf{s}$ ni por $\mathbf{e}$

$$(\hat{i}, \hat{j}) = \arg \max_{j \geq i} (\mathbf{s} \cdot \mathbf{z}_i + \mathbf{e} \cdot \mathbf{z}_j)$$

con $j \geq i$, por construcción



La salida es un par de posiciones

No una etiqueta ni un texto nuevo.

El cabezal es una $\mathbf{W}$ de $2 \times H$

Sus dos filas son los vectores de inicio y de fin.

Y el encoder se ajusta con él

Con dos vectores y el encoder congelado, esto no funcionaría.

Devlin et al., NAACL 2019. SQuAD reúne 100.000 preguntas anotadas sobre párrafos de Wikipedia.

Las tareas de GLUE

Ocho tareas de comprensión, todas de clasificación o regresión sobre oraciones. Seis reciben un par y dos una sola oración.

tarea	qué se decide	un ejemplo del conjunto	etiqueta
reciben un par de oraciones			
MNLI	implica, contradice o ...	Don't remember. Yes, I remember.	contradiction
QNLI	¿responde la pregunta?	How many sacks did Derek Wolfe ... each had 5½ sacks.	entailment
QQP	¿son la misma pregunta?	Who is Miya Ali? Who is Ali Daei?	not_duplicate
RTE	¿la primera implica la ...	The girl was found in Drummondville. Drummondville contains the girl.	not_entailment
MRPC	¿dicen lo mismo?	McCabe said he was considered a ... " He is not considered a suspect , " ...	not_equivalent
STS-B	cuánto se parecen, 0 a 5	A man is dancing. A man is singing.	1,25
reciben una sola oración			
SST-2	¿positiva o negativa?	this is so bad .	negative
CoLA	¿es gramatical?	I shaped a loaf.	unacceptable
ninguna es de etiquetado por posición; eso se mide en CoNLL, y la extracción de respuesta en SQuAD			
MNLI	multi-genre natural language inference		MRPC Microsoft Research paraphrase corpus
QNLI	question natural language inference		STS-B semantic textual similarity benchmark
QQP	Quora question pairs		SST-2 Stanford sentiment treebank
RTE	recognizing textual entailment		CoLA corpus of linguistic acceptability

Wang et al., 2018. Ejemplos del conjunto de validación de cada tarea. GLUE viene de General Language Understanding Evaluation.

GLUE

La colección de tareas con la que se comparan encoders. Se ajusta el mismo modelo por separado en cada una.

tarea	ejemplos	BERT	RoBERTa	diferencia
MNLI	392 K	86,6	90,2	+3,6
QQP	363 K	91,3	92,2	+0,9
QNLI	108 K	92,3	94,7	+2,4
SST-2	67 K	93,2	96,4	+3,2
CoLA	8,5 K	60,6	68,0	+7,4
STS-B	5,7 K	90,0	92,4	+2,4
MRPC	3,5 K	88,0	90,9	+2,9
RTE	2,5 K	70,4	86,6	+16,2


la ventaja de RoBERTa crece a medida que baja el tamaño del conjunto de entrenamiento

Multilingual BERT

El mismo encoder entrenado sobre 104 idiomas a la vez. Con eso el ajuste supervisado se hace en un idioma y la tarea se resuelve en los demás, que es lo que se llama transferencia zero-shot.

idiomas	104 en la versión cased, 102 en la original
corpus	la Wikipedia completa de cada uno, sin páginas de usuario
vocabulario	WordPiece compartido, 119.547 piezas para todos
muestreo	suavizado exponencial con $S = 0,7$, para no aplastar a los idiomas chicos
arquitectura	la misma de BERT base; el encoder pesa 86.041.344, igual que el suyo
datos paralelos	ninguno: cada ejemplo de preentrenamiento está en un solo idioma

transferencia zero-shot, ajuste supervisado en inglés y evaluación en los demás sin ejemplos



el primero es el idioma del ajuste; los demás nunca vieron un ejemplo anotado

Documentación de google-research/bert. Ajuste sobre las 392.702 premisas e hipótesis en inglés de MNLI; evaluación sobre las 5.010 de XNLI en cada idioma.