



IIC3670 Procesamiento de Lenguaje Natural


<https://github.com/marcelomendoza/IIC3670>

- GENERACIÓN DE TEXTO -

Generación de texto


c puede representar un tema u otra oración

Transducer condicional (generador):




Seq2seq

Transducer condicional




Encoder




Seq2seq

- Aplicación más conocida de la arquitectura: **Machine translation**




- Otras: **QA (closed)**

Generación condicional con atención (Google translation original)




Generación condicional con atención (transformer seq2seq, T5)




El tipo de atención está relacionado con la arquitectura del transformer

Causal




Decoder

Bidireccional



Encoder

Condicional (cross)




Encoder-Decoder

T5 requiere data paralela


E1: "Good morning," said the little prince.	F1: -Bonjour, dit le petit prince.
E2: "Good morning," said the merchant.	F2: -Bonjour, dit le marchand de pilules perfectionnées qui apaisent la soif.
E3: This was a merchant who sold pills that had been perfected to quench thirst.	F3: On en avale une par semaine et l'on n'éprouve plus le besoin de boire.
E4: You just swallow one pill a week and you won't feel the need for anything to drink.	F4: -C'est une grosse économie de temps, dit le marchand.
E5: "They save a huge amount of time," said the merchant.	F5: Les experts ont fait des calculs.
E6: "Fifty-three minutes a week."	F6: On épargne cinquante-trois minutes par semaine.
E7: "If I had fifty-three minutes to spend?" said the little prince to himself.	F7: "Moi, se dit le petit prince, si j'avais cinquante-trois minutes à dépenser, je marcherais tout doucement vers une fontaine..."
E8: "I would take a stroll to a spring of fresh water"	

No siempre el alineamiento es 1 a 1.

T5 requiere data paralela y generación autorregresiva en el decoder



El decoder de T5 usa dos tipos de mecanismos de atención



Cross-attention usa condicionantes en el mecanismo de atención

Opción 1) Se condiciona K y V:

$$Q = H^{\text{dec}[\ell-1]} W^Q, \quad K = H^{\text{enc}} W^K, \quad V = H^{\text{enc}} W^V$$

$$\text{CrossAttention}(Q, K, V) = \text{softmax}\left(\frac{QK^\top}{\sqrt{d_k}}\right) V$$

Opción 2) Se condiciona Q y K:

$$Q = H^{\text{enc}} W^Q, \quad K = H^{\text{enc}} W^K, \quad V = H^{\text{dec}[\ell-1]} W^V$$

$$\text{CrossAttention}(Q, K, V) = \text{softmax}\left(\frac{QK^\top}{\sqrt{d_k}}\right) V$$

Los coeficientes de atención están condicionados al encoder!!


Aspectos relevantes de la decodificación

Greedy decoding:

$$\hat{w}_t = \operatorname{argmax}_{w \in V} P(w | \mathbf{w}_{<t})$$


Tiene la limitación de que está condicionada por los tokens anteriores, y pierde el contexto hacia adelante.

Beam search: construir alternativas y escoger la más probable al llegar a EOS.



¿Cómo funciona Beam Search?


Escogemos k posibles tokens para el siguiente paso. El ancho del beam está determinado por k .



¿Cómo funciona Beam Search?

Los top-k hijos se expanden.

$$\begin{aligned} score(y) &= \log P(y|x) \\ &= \log (P(y_1|x)P(y_2|y_1,x)P(y_3|y_1,y_2,x)...P(y_t|y_1,...,y_{t-1},x)) \\ &= \sum_{i=1}^t \log P(y_i|y_1,...,y_{i-1},x) \end{aligned}$$



¿Cómo evaluamos el texto generado?

Si tenemos una respuesta de referencia podemos comparar n-grams. Hay varias métricas basadas en match léxico, por ejemplo BLEU. Pero para capturar semántica necesitamos algo más.

BERTScore (model-based metric):

