




IIC3670 Procesamiento de Lenguaje Natural

<https://github.com/marcelomendoza/IIC3670>

- SINTONÍA FINA (FINE TUNING) EN ENCODERS -


Transformer encoder

Los encoders preentrenados, como BERT, sBERT o RoBERTa (una extensión robusta y multilingual de BERT) se pueden usar para entrenar modelos en *downstream tasks*. En este caso, se hace un FT **supervisado** en el top del modelo, dejando congelado los embeddings preentrenados.




Transformer encoder

Los encoders preentrenados, como BERT, sBERT o RoBERTa se pueden usar para entrenar modelos en etiquetados de secuencias, como por ejemplo *named entity recognition (NER)*. En este caso, se hace un FT supervisado en el top del modelo a nivel de cada token. A la tarea se le denomina **clasificación a nivel de token**.




Encoders y codificación de entrada


SFT se usa en transformers encoders preentrenados para muchas tareas. Dependiendo del tipo de tarea, la entrada deberá ser codificada de una forma específica. Se suele usar [CLS] y [SEP] para codificación de entrada.




(a) Sentence Pair Classification Tasks:
MNLI, QQP, QNLI, STS-B, MRPC,
RTE, SWAG



(b) Single Sentence Classification Tasks:
SST-2, CoLA




(c) Question Answering Tasks:
SQuAD v1.1



(d) Single Sentence Tagging Tasks:
CoNLL-2003 NER


Token level y span level

SFT se usa en transformers encoders preentrenados para **clasificación a nivel de span**. La idea es usar cabezales informados por NER para construir representaciones a nivel de span (n -grams) y clasificar a nivel de span.



Pre-entrenamiento continuo

Un transformer encoder pre-entrenado se puede adaptar a un nuevo dominio haciendo FT autosupervisado sobre nuevos datos. Se usa MLM para este tipo de FT. En este caso el encoder se reentrena.




- PRE-ENTRENAMIENTO EN DECODERS -

Next Token Prediction (masivo)


Un transformer decoder puede ser pre-entrenado para la tarea next token prediction de manera de crear un modelo de lenguaje. Dado que el entrenamiento es auto-supervisado, podemos usar muchos datos.

Si usamos muchos datos (pre-entrenamiento masivo), al modelo pre-entrenado lo denominamos **Large Language Model (LLM)**.



Datos masivos

Se requieren muchos datos de texto. Estos incluyen distintos corpus, con variedad temática. The Pile es uno de los primeros que se creó, sobre la base de textos en inglés. Tenía app. 825 GB de texto.



GPT 1

GPT-1 usó un preentrenamiento en NTP + una tarea supervisada, al estilo BERT.

$$L_1(\mathcal{U}) = \sum_i \log P(u_i | u_{i-k}, \dots, u_{i-1}; \Theta) \quad \text{Transformer decoder}$$

$$P(y | x^1, \dots, x^m) = \text{softmax}(h_l^m W_y).$$

en NTP y es un token

en clasificación y es una clase


Última capa del transformer decoder

$$L_2(\mathcal{C}) = \sum_{(x,y)} \log P(y | x^1, \dots, x^m).$$

La pérdida combinada es:

$$L_3(\mathcal{C}) = L_2(\mathcal{C}) + \lambda * L_1(\mathcal{C})$$

GPT 1 resuelve ambas tareas simultáneamente (LM y specific task)




Radford, A., Narasimhan, K., Salimans, T., Sutskever, I. Improving language understanding by generative pre-training, 2018.

GPT 1

GPT 1 usó SFT de la misma manera en que la usó BERT, es decir, usa los embeddings del decoder para la tarea.

La secuencia de entrada depende de la tarea



Aspectos de la decodificación de texto en GPT

Greedy decoding:

$$\hat{w}_t = \operatorname{argmax}_{w \in V} P(w | \mathbf{w}_{<t})$$

Top-k sampling: trunca la distribución a las top-k palabras más probables y renormaliza. Luego aplica greedy decoding sobre la distribución resultante.

Top-p sampling: en lugar de truncar sobre los k primeros, tomamos las palabras que están en el top-p de probabilidad. Por ejemplo, si $p=0.5$, k corresponde al listado de palabras que cubren el 50% de la masa de la distribución de probabilidad:


$$\sum_{w \in V(p)} P(w | \mathbf{w}_{<t}) \geq p.$$

Aspectos de la decodificación de texto en GPT

Temperature sampling: dividimos el logit por la temperatura. Temperaturas bajas están en]0, 1]. Temperaturas altas son > 1 .

$$\mathbf{y} = \text{softmax}(u/\tau)$$


Cuando la temperatura es cercana a 1, los logits quedan igual y la distribución no cambia. Pero cuando la temperatura es baja, aumenta la probabilidad de los más probables. Ir a temperaturas altas tiende a la distribución uniforme.



- FT EN DECODERS -


FT en LLMs

El ajuste fino (fine-tuning) permite adaptar el LLM a dominios específicos. Los datos de FT suelen ser mucho menos que los necesarios para preentrenamiento. También suelen ser datos de mejor calidad.




La idea de prefix tuning

Podemos congelar el ajuste para un prefijo (instrucción) y hacer FT sólo para la respuesta. El FT puede ser con autocompletación sobre un dataset de instrucciones. Esto permite tener un FT autosupervisado.



Datasets de instrucciones

Instruction FT tiene por objetivo ajustar el LLM sobre muchas tareas. Se basa en NTP y se realiza sobre la completación (supervisada) de la respuesta.



Los LLMs se benefician de datasets de instrucciones, los cuales les muestran distintos tipos de tareas. Si bien no adquieren todas las respuestas desde estos datasets, adquieren la capacidad de buscar esta información, alineando la salida generada con la instrucción.

Ejemplos de datasets de instrucciones:

Aya corpus: 500 millones de instrucciones en 114 idiomas en 12 tareas.

Supernatural: 12 millones de ejemplos en 1600 tareas.

Tareas usuales: QA, NLI, traducción, resumir, ...

Datasets de instrucciones

Las instrucciones son de distinto tipo, y contienen la respuesta esperada. Al hacer FT sobre el dataset, ajustamos el modelo para generar la respuesta esperada usando autocompletación.

Original Article

The only thing crazier than a guy in snowbound Massachusetts boxing up the powdery white stuff and offering it for sale online? People are actually buying it. For \$89, self-styled entrepreneur Kyle Waring will ship you 6 pounds of Boston-area snow in an insulated Styrofoam box – enough for 10 to 15 snowballs, he says.

But not if you live in New England or surrounding states. “We will not ship snow to any states in the northeast!” says Waring’s website, ShipSnowYo.com. “We’re in the business of expunging snow!”

His website and social media accounts claim to have filled more than 133 orders for snow – more than 30 on Tuesday alone, his busiest day yet. With more than 45 total inches, Boston has set a record this winter for the snowiest month in its history. Most residents see the huge piles of snow choking their yards and sidewalks as a nuisance, but Waring saw an opportunity.

According to Boston.com, it all started a few weeks ago, when Waring and his wife were shoveling deep snow from their yard in Manchester-by-the-Sea, a coastal suburb north of Boston. He joked about shipping the stuff to friends and family in warmer states, and an idea was born. [...]

Summary

Kyle Waring will ship you 6 pounds of Boston-area snow in an insulated Styrofoam box – enough for 10 to 15 snowballs, he says. But not if you live in New England or surrounding states.

Datasets de instrucciones

Dependiendo de la instrucción, podemos usar palabras reservadas durante FT para usarlas en prompts. Por ejemplo, podemos usar `tl;dr`.

