



PONTIFICIA
UNIVERSIDAD
CATÓLICA
DE CHILE

Procesamiento de Lenguaje Natural

github.com/marcelomendoza/IIC3670

Marcelo Mendoza

Perplejidad

La medida con que se sigue el preentrenamiento de un modelo de lenguaje. Es la exponencial de la pérdida, y se lee como la cantidad de tokens entre los que el modelo duda en promedio.

$$\mathcal{L} = -\frac{1}{T} \sum_{t=1}^T \log p_t, \quad p_t = \hat{y}_t[w_{t+1}]$$


la pérdida de next token prediction

$$\mathbf{PPL} = e^{\mathcal{L}} = \prod_{t=1}^T e^{-\frac{1}{T} \log p_t} = \prod_{t=1}^T p_t^{-1/T} = \frac{1}{(\prod_t p_t)^{1/T}} = \frac{1}{\bar{p}}$$

$\bar{p}$: media geométrica de las p_t

$$\text{PPL} = 1 \text{ si } p_t = 1, \quad \text{PPL} = |\mathcal{V}| \text{ si } \hat{y}_t = \frac{1}{|\mathcal{V}|}$$


modelo seguro y modelo uniforme



Jelinek et al., 1977; Jurafsky y Martin, Speech and Language Processing.

Por qué varía la perplejidad

Depende de qué tan esperable es cada token para el modelo. Cambia con el largo del texto, con el idioma y con el orden de las palabras.



Suavizamiento exponencial

En un preentrenamiento multilingüe, cada idioma se muestra con su proporción elevada a $\alpha < 1$. Los idiomas con poco texto se ven más seguido y el dominante, menos.

$$q_i = \frac{n_i}{\sum_j n_j}$$

proporción del idioma i en el corpus


$$p_i = \frac{q_i^\alpha}{\sum_j q_j^\alpha}, \quad 0 < \alpha \leq 1$$

probabilidad de muestrear el idioma i

$$\alpha = 1 : p_i = q_i,$$

$$\alpha \rightarrow 0 : p_i \rightarrow \text{uniforme}$$

mBERT usa $\alpha=0,7$; XLM-R, $\alpha=0,3$



Devlin et al., NAACL 2019; Conneau et al., ACL 2020. Proporciones ilustrativas.


Encoder-decoder

Un encoder lee la oración fuente y un decoder genera la traducción token a token. Se entrena con un corpus paralelo, y su aplicación principal es la traducción automática.

$$P(w_1, \dots, w_m \mid x_1, \dots, x_n) = \prod_{i=0}^{m-1} P(w_{i+1} \mid w_0, \dots, w_i, \mathbf{x}_1, \dots, \mathbf{x}_n) \quad \text{un modelo de lenguaje condicionado a la fuente}$$

$$\mathbf{H}^{\text{enc}} = \text{Encoder}(x_1, \dots, x_n) = [h_1^{\text{enc}}, \dots, h_n^{\text{enc}}] \quad \text{se calcula una sola vez}$$


$$\hat{y}_i = \text{Decoder}(w_0, \dots, w_i, \mathbf{H}^{\text{enc}}) \quad \hat{y}_i[w] = P(w_{i+1}=w \mid w_{\leq i}, x)$$



Sutskever, Vinyals y Le, NeurIPS 2014; Vaswani et al., NeurIPS 2017; Jurafsky y Martin, Speech and Language Processing.

Tres atenciones


El encoder usa atención global y el decoder atención causal. La cross-attention conecta los dos: cada posición del decoder atiende a todas las posiciones de la fuente.



filas del decoder, columnas del encoder

El bloque del decoder

El bloque del decoder agrega una subcapa entre la atención causal y la red por posición. Esa subcapa es la cross-attention, y recibe la salida del último bloque del encoder.



Ecuaciones de transferencia del decoder

El bloque del decoder lleva una subcapa más, la cross-attention con su residual, entre la atención causal y la red por posición.

$d_i = e_i + \text{PE}(i)$	embedding del token w_i más posición
$a_i = \text{MultiHead}(d_i, [d_1, \dots, d_j]), \quad j \leq i$	atención causal sobre la traducción
$z_i = \text{LayerNorm}(d_i + a_i)$	residual y normalizar
$\mathbf{c}_i = \text{CrossAttn}(z_i, [h_1^{\text{enc}}, \dots, h_n^{\text{enc}}])$	cross-attention sobre toda la fuente
$\tilde{z}_i = \text{LayerNorm}(z_i + \mathbf{c}_i)$	residual y normalizar
$f_i = W_2 \max(0, W_1 \tilde{z}_i)$	red por posición
$y_i = \text{LayerNorm}(\tilde{z}_i + f_i)$	salida del bloque, entrada del siguiente
$\hat{y}_i = \text{softmax}(Uh_i), \quad h_i = y_i^{(L)}$	cabecal sobre el último de los L bloques

Cross-attention

La consulta sale del decoder y las claves y los valores salen del encoder. Los coeficientes se normalizan sobre las n posiciones de la fuente.

$$q_i = W^Q \mathbf{z}_i$$

la consulta viene del decoder

$$k_j = W^K \mathbf{h}_j^{\text{enc}}, \quad v_j = W^V \mathbf{h}_j^{\text{enc}}$$

claves y valores vienen del encoder

$$\alpha_{ij} = \text{softmax}_{j=1, \dots, n} \left(\frac{q_i \cdot k_j}{\sqrt{d_k}} \right)$$

sobre las n posiciones de la fuente, sin máscara

$$\text{head}_i = \sum_{j=1}^n \alpha_{ij} v_j$$

una mezcla de la fuente para la posición i

$$c_i = W^O (\text{head}_i^1 \oplus \dots \oplus \text{head}_i^A)$$


concatenación de los A cabezales

$$\text{softmax} \left(\frac{Q K^\top}{\sqrt{d_k}} \right) V, \quad Q \in \mathbb{R}^{m \times d_k} \text{ del decoder}, \quad K, V \in \mathbb{R}^{n \times d_k} \text{ del encoder}, \quad Q K^\top \in \mathbb{R}^{m \times n}$$

En forma matricial: la matriz de coeficientes es de $m \times n$.


Cross-attention para una posición

La posición de «bruja» consulta las cinco posiciones de la fuente. El coeficiente más alto es el de «witch», y la salida es la suma de los valores ponderada por los coeficientes.



Cross-attention medida


Cada fila es una posición del decoder, que recibe un token y produce el siguiente. En la capa 3 atiende a la palabra fuente del token que recibe, y en la capa 5 a la del token que produce.



Entrenamiento con datos paralelos

Next token prediction sobre la traducción, condicionado a la fuente. El gradiente llega al encoder a través de la cross-attention.

$$\mathcal{L} = -\frac{1}{N} \sum_{(x, w) \in \mathcal{D}} \frac{1}{m} \sum_{i=0}^{m-1} \log \hat{y}_i[w_{i+1}] \quad \mathcal{D}: \text{ corpus paralelo de } N \text{ pares}$$
$$\hat{y}_i = \text{Decoder}(w_0, \dots, w_i, \text{Encoder}(x)) \quad \text{el prefijo es la traducción de referencia}$$



Preentrenar para traducir

Primero el modelo aprende a reconstruir texto tapado en cada idioma, sin datos paralelos. Después se ajusta con el corpus paralelo para traducir.

Paso 1. Preentrenamiento sin datos paralelos, cada idioma por separado

span corruption (T5, mT5), inglés

encoder recibe The green <X> arrived in the <Y> yesterday.

decoder genera <X> witch <Y> village <Z>

text infilling (BART, mBART), español

encoder recibe La bruja <mask> llegó ayer <mask> pueblo.

decoder genera La bruja verde llegó ayer al pueblo.

Paso 2. Ajuste para traducir con el corpus paralelo, desde los pesos del paso 1

encoder recibe The green witch arrived in the village yesterday.

decoder genera La bruja verde llegó ayer al pueblo.

Encoder-decoder sin traducción

La entrada y la salida están en el mismo idioma. El modelo se preentrena reconstruyendo texto tapado y se ajusta a una tarea cuya salida es texto. Así se usan BART y T5.

Paso 1. Preentrenamiento con texto en inglés, text infilling

encoder recibe Thank you <mask> me to your party <mask> week.

decoder genera Thank you for inviting me to your party last week.

Paso 2. Ajuste para resumir, en el mismo idioma

encoder recibe

(CNN)For the first time in eight years, a TV legend returned to doing what he does best. Contestants told to "come on down!" on the April 1 edition of "The Price Is Right" encountered not host Drew Carey but another familiar face in charge of the proceedings. Instead, there was Bob Barker, who hosted the TV game show for 35 years before ...

decoder genera

Bob Barker returned to host "The Price Is Right" for the first time in eight years. Barker hosted the TV game show for 35 years before stepping down in 2007. He handled the first price-guessing game of the show, the classic "Lucky Seven"

Modelos encoder-decoder preentrenados

Ninguno se preentrena con datos paralelos. Se preentrenan con texto sin anotar y la traducción se aprende en el ajuste supervisado.

Modelo	Preentrenamiento	Corpus	Idiomas	Parámetros
T5	span corruption	C4, 750 GB	inglés	61 M a 11 B
mT5	span corruption	mC4, 6,3 T tokens	101	300 M a 13 B
BART	text infilling	160 GB, los de RoBERTa	inglés	139 M y 406 M
mBART	text infilling	CC25	25	611 M

C4 es el Colossal Clean Crawled Corpus, texto web filtrado en inglés, y mC4 su versión multilingüe. Los 160 GB de BART son noticias, libros, historias y texto web en inglés. BART es Bidirectional and Auto-Regressive Transformers. Raffel et al., 2020; Xue et al., 2021; Lewis et al., 2020; Liu et al., 2020.

Traducción y corpus paralelos

Los modelos dedicados a traducir se entrenan con corpus paralelos. Hay corpus grandes para pocos idiomas, y para el resto los pares se minan de la web.

Corpus	Origen	Idiomas	Tamaño
Europarl	actas del Parlamento Europeo	21	0,4 a 2 M por idioma
UN Parallel Corpus	documentos oficiales de la ONU	6	10 M oraciones
ParaCrawl	sitios web traducidos	24	223 M pares
NLLB	minado de la web	148	1.100 M pares

Modelos de traducción

OPUS-MT tiene un modelo por par de idiomas, entrenado solo con OPUS. Hay 1.550.

NLLB-200 traduce entre 200 idiomas con un solo modelo.

Koehn, 2005; Ziemski et al., 2016; Bañón et al., 2020; Tiedemann y Thottingal, EAMT 2020; NLLB Team, 2022.

Minería de pares paralelos

Cada oración se codifica con LaBSE, un encoder tipo BERT compartido por 109 idiomas, y su vector es la salida de [CLS], de 768 dimensiones. Una oración y su traducción quedan en vectores cercanos.

oración en inglés la más cercana en español	coseno	oración en inglés la más cercana en español	coseno
The green witch arrived in the village yesterday. La bruja verde llegó ayer al pueblo.	0,92 ✓	She wrote a long letter to her mother. Ella le escribió una carta larga a su madre.	0,90 ✓
The students opened their books. Los estudiantes abrieron sus libros.	0,96 ✓	The weather was very cold this morning. La temperatura bajó de golpe en la tarde.	0,62 ✗
The museum closes at six in the evening. El museo cierra a las seis de la tarde.	0,96 ✓	The company reported higher profits this year. La cosecha de uva fue abundante este año.	0,59 ✗
My brother bought a new car last week. Mi hermano compró un auto nuevo la semana pasada.	0,93 ✓	He forgot his keys at the office. La profesora explicó la tarea dos veces.	0,37 ✗

coseno entre los embeddings de LaBSE, umbral 0,8

Respuesta a preguntas con T5

Un par de pregunta y respuesta es un par paralelo más. La pregunta y el contexto entran al encoder, y el decoder genera la respuesta en lugar de extraerla.

encoder recibe

question: Where was Neruda born? context: Neruda was born in Parral, Chile, in 1904. He received the Nobel Prize in Literature in 1971.

decoder genera

Parral, Chile

pregunta

Where was Neruda born?

What prize did Neruda receive?

Where did Neruda die?

How old was Neruda when he received the Nobel Prize?

respuesta de T5

Parral, Chile

Nobel Prize in Literature

Chile
no está en el contexto

1904
había que calcular 1971 – 1904

Un decoder con prefijo

Un decoder resuelve la misma tarea si el contexto y la pregunta van como prefijo. Para entrenarlo, solo las posiciones que predicen la respuesta aportan a la pérdida.

$$w_1, \dots, w_p \mid w_{p+1}, \dots, w_T$$


prefijo | respuesta

$$m_t = \begin{cases} 0 & t < p \\ 1 & t \geq p \end{cases}$$

la posición t predice w_{t+1}

$$\mathcal{L} = -\frac{\sum_t m_t \log \hat{y}_t[w_{t+1}]}{\sum_t m_t}$$

solo la respuesta aporta a la pérdida



Ajuste con instrucciones

Un ajuste supervisado del modelo preentrenado con pares de instrucción y respuesta, con la pérdida sobre la respuesta. Es el primer paso con que se construyó InstructGPT sobre GPT-3.

$$w^{(n)} = \text{plantilla}(x^{(n)}) \oplus y^{(n)} \oplus \langle /s \rangle$$

(n): el par n de los N; x instrucción, y respuesta

$$\mathcal{L} = -\frac{1}{N} \sum_{n=1}^N \frac{1}{M_n} \sum_t m_t^{(n)} \log \hat{y}_t^{(n)}[w_{t+1}^{(n)}]$$

$m_t^{(n)}=1$ solo sobre la respuesta

$$\eta_s = \eta_{\min} + \frac{1}{2}(\eta_0 - \eta_{\min})(1 + \cos(\pi s/S))$$

decaimiento coseno: la tasa del paso s baja de η_0 a $\eta_{\min}$

Una secuencia de entrenamiento

instrucción, m = 0 <s> [INST] Translate to Spanish: The green witch arrived in the village yesterday. [/INST]

respuesta, m = 1 La bruja verde llegó ayer al pueblo. </s>

InstructGPT, paso 1 12.725 pares · todos los pesos · 16 épocas
tasa 9,65e-6 con decaimiento coseno · batch 32 · dropout 0,2

La misma instrucción, «Translate to Spanish: The green witch arrived in the village yesterday.»

Mistral-7B base She was a tall, thin woman with long, stringy hair and a face that looked like it had been carved out of wood. She wore a long, green dress and a pointed hat, and ...

Mistral-7B-Instruct La bruja verde llegó al pueblo ayer.

Datasets de instrucciones

Todos están publicados en Hugging Face. Traen instrucciones de generación, preguntas abiertas y cerradas, lluvia de ideas, clasificación, extracción, resumen y reescritura.

Dataset	Quién escribe los pares	Tamaño	Modelos ajustados
Super-NaturalInstructions	expertos, sobre tareas de NLP	1.616 tareas	Tk-Instruct (T5)
FLAN	colecciones de tareas	1.836 tareas	Flan-T5
Alpaca	un LLM, text-davinci-003	52.002 pares	Alpaca (LLaMA 7B)
Dolly	empleados de Databricks	15.011 pares	Dolly 2.0 (Pythia 12B)
OASST1	voluntarios, en conversación	88.838 mensajes	OpenAssistant (Pythia, LLaMA)
Aya	hablantes de 65 idiomas	204.112 pares	Aya (mT5 13B)

Wang et al., EMNLP 2022; Chung et al., JMLR 2024; Taori et al., 2023; Conover et al., 2023; Köpf et al., NeurIPS 2023; Singh et al., ACL 2024.

Generalización a tareas no vistas


FLAN (Finetuned Language Net) se ajusta con instrucciones de todos los grupos de tareas menos uno y se evalúa en el grupo retenido, que no vio. Con solo la instrucción, supera a GPT-3, más grande y sin ese ajuste.

doce grupos de tareas

inferencia (NLI)	sentido común
sentimiento	paráfrasis
preguntas sin contexto	datos a texto
traducción	comprensión de lectura
lectura y sentido común	correferencia
otras	resumen


ajuste con instrucciones

retenido, se evalúa



Qué permite generalizar

El desempeño en las tareas retenidas sube con la cantidad de grupos de tareas del ajuste, y cae si en el ajuste no se escriben las instrucciones.



cómo se escribe la entrada en el ajuste

sin instrucción

«The dog runs.»

37,3

con el nombre del dataset

«[Translation: WMT'14 to French] The dog runs.»

46,6

con una instrucción (FLAN)

«Please translate this sentence to French: 'The dog runs.'»

55,2

promedio en cuatro grupos retenidos (%); al evaluar, todos reciben la instrucción