



PONTIFICIA
UNIVERSIDAD
CATÓLICA
DE CHILE


Procesamiento de Lenguaje Natural

github.com/marcelomendoza/IIC3670

Marcelo Mendoza

El post-training de un LLM

Entre el modelo base y el modelo publicado hay varias etapas. Cada laboratorio combina un subconjunto distinto, y la receta cambia de un año a otro.



CPT: continued pretraining. SFT: supervised fine-tuning. RL: reinforcement learning. RM: modelo de recompensa. DPO, PPO y GRPO: algoritmos de ajuste.

Annealing final: bajar la tasa de aprendizaje a cero al final del preentrenamiento, sobre datos de alta calidad.

Cold start: un primer SFT con pocos miles de ejemplos de razonamiento, antes del RL. Fusión de modos: SFT con y sin razonamiento.

AI2: Allen Institute for AI, instituto sin fines de lucro que publica modelos, datos y código completos. 128K: largo máximo de la entrada, en tokens.

Preferencias: ajuste con pares de respuestas en que una es mejor que la otra. Destilación: entrenar un modelo con las salidas de otro.

Llama Team, 2024; Lambert et al., 2024; DeepSeek-AI, Nature 2025; Qwen Team, 2025; Olmo Team, 2025; DeepSeek-AI, 2026.

Continued pretraining (CPT)

Se sigue entrenando el modelo base con la misma pérdida de next token prediction, sobre un corpus de otro dominio, idioma o tipo de texto.

Modelo	Parte de	Corpus nuevo	Tokens	Replay
Code Llama	Llama 2	código	500.000 millones	7 %
Meditron-70B	Llama 2 70B	guías clínicas y PubMed	48.100 millones	1 %
SaulLM-7B	Mistral 7B	textos legales	30.000 millones	2 %


Replay: fracción de los datos de entrenamiento que se toma de un corpus general, como el del preentrenamiento. Rozière et al., 2023; Chen et al., 2023; Colombo et al., 2024.

Olvido catastrófico y replay

Entrenar solo con el corpus nuevo degrada lo aprendido antes. Se controla mezclando una fracción del corpus original y volviendo a subir la tasa de aprendizaje.

$$\mathcal{L} = -\frac{1}{T} \sum_{t=1}^T \log \hat{y}_t[w_{t+1}], \quad w \sim (1 - \rho) \mathcal{D}_{\text{nuevo}} + \rho \mathcal{D}_{\text{general}} \quad \rho: \text{fracción de replay del corpus original}$$


$$\eta_s = \begin{cases} \eta_{\max} s / S_w & s \leq S_w \\ \eta_{\min} + \frac{1}{2}(\eta_{\max} - \eta_{\min}) \left(1 + \cos\left(\pi \frac{s - S_w}{S - S_w}\right)\right) & s > S_w \end{cases} \quad \eta_s: \text{tasa del paso } s \text{ de } S; \text{ sube a } \eta_{\max} \text{ en } S_w \text{ pasos y decae a } \eta_{\min}$$



Gupta et al., 2023; Ibrahim et al., TMLR 2024. Curva ilustrativa.

Mid-training

Al final del preentrenamiento, la tasa de aprendizaje baja a cero sobre una mezcla de datos de mayor calidad. En OLMo 2 esa mezcla es Dolmino, armada por AI2 para esta etapa.



web general: 3,90 billones de tokens

Dolmino: 50.000 millones

mezcla de AI2 para el mid-training:
web filtrada por calidad, matemática,
Wikipedia, artículos científicos

De la respuesta directa a los pasos

Un LLM responde directo. Pero si en el prompt se le pide razonar paso a paso, o se le muestran ejemplos resueltos por pasos, escribe pasos intermedios antes del resultado, y acierta mucho más.

respuesta directa

Q: Natalia sold clips ... altogether in April and May?
A:

→ el modelo escribe un número

una frase que pide pasos

Q: Natalia sold clips ... altogether in April and May?
A: Let's think step by step.


→ escribe pasos y después el número

ejemplos resueltos paso a paso

Q: (otro problema) A: (su solución por pasos)
... ocho ejemplos ...
Q: Natalia sold clips ...? A:

→ imita el formato: pasos y número

exactitud en GSM8K (%):
directa contra con pasos



GSM8K (Grade School Math 8K): 8.500 problemas de matemática de enseñanza básica con su solución; Cobbe et al., 2021. Wei et al., NeurIPS 2022; Kojima et al., NeurIPS 2022.

Del prompt al modelo de razonamiento

Un modelo de razonamiento se entrena con respuestas que incluyen los pasos, entre los tokens `<think>` y `</think>`. Después escribe pasos siempre, sin que el prompt lo pida.

Entrenamiento: una secuencia de SFT con la traza dentro de la respuesta

usuario	Natalia sold clips to 48 of her friends in April, and then she sold half as many clips in May. How many clips did Natalia sell altogether in April and May?	m = 0
razonamiento	<code><think></code> Natalia sold $48/2 = 24$ clips in May. Natalia sold $48+24 = 72$ clips altogether in April and May. <code></think></code>	m = 1
respuesta	The answer is 72.	m = 1

la traza es la solución que escribió una persona en GSM8K; la pérdida se calcula sobre ella igual que sobre la respuesta

Uso: la plantilla abre `<think>`, y el modelo continúa con los pasos

usuario: (otro problema)	asistente: <code><think></code>	→ pasos ...
--------------------------	---------------------------------------	-------------

el prompt no pide razonar: el modelo lo hace porque así terminaban todas las respuestas con que se ajustó

Por qué ayudan los pasos

El transformer hace una cantidad fija de cómputo por token. Escribir K pasos le da K pasadas más antes de responder, y cada resultado intermedio queda en el contexto.

$$y = \langle \text{think} \rangle z_1, \dots, z_K \langle \text{think} \rangle a_1, \dots, a_M$$

z : razonamiento; a : respuesta

$$\hat{z}_k \sim \hat{y}(\cdot \mid x, z_{<k}), \quad \hat{a}_m \sim \hat{y}(\cdot \mid x, z, a_{<m})$$

la respuesta atiende al razonamiento

cómputo antes de $a_1 = (K + 1) \cdot L$ capas contra L sin razonamiento

L : bloques del transformer

respuesta directa: una pasada por las L capas antes del resultado



con pasos intermedios: una pasada por token, y cada resultado queda en el contexto



el paso siguiente atiende a 24 ya escrito: no tiene que calcularlo otra vez dentro de sus capas

Solución de GSM8K para el problema de Natalia, escrita por una persona: «Natalia sold 48/2 = 24 clips in May. Natalia sold 48+24 = 72 ...»

De dónde vienen las trazas

La capacidad viene del preentrenamiento. Las trazas para entrenar salen de personas, del propio modelo filtrado por si acierta, del RL o de un modelo más grande.

1. preentrenamiento

Wei et al., NeurIPS 2022

la web tiene muchas soluciones resueltas paso a paso; el modelo base ya escribe pasos intermedios si se le pide, sobre todo si es grande

2. SFT sobre trazas del propio modelo

Zelikman et al., NeurIPS 2022 (STaR)

el modelo genera razonamientos para problemas con solución conocida; se conservan los que llegan a la solución correcta y se ajusta con ellos, por rondas

3. aprendizaje por refuerzo (RL)

DeepSeek-AI, Nature 2025 (R1-Zero)

el modelo prueba respuestas y se refuerzan las que llegan al resultado correcto; razonar más largo, verificar y corregir aparecen solos, porque aumentan los aciertos

4. destilación

DeepSeek-AI, Nature 2025 (R1-Distill)

SFT de un modelo chico con los razonamientos que genera uno grande; en modelos chicos rinde más que el RL directo

Un modelo de razonamiento

El mismo problema, dos modelos de 1.500 millones de parámetros. El segundo se entrenó con trazas de DeepSeek-R1: razona entre `<think>` y `</think>` sin que el prompt lo pida.

Qwen2.5-1.5B-Instruct
responde directo

It takes a total of 6 bolts of fabric because $1 + 0.5 = 1.5$; $1.5 * 4 = 6$ Therefore, the answer is `\boxed{6}`.

45 tokens
responde 6: incorrecto

`\boxed{ }`: recuadro de LaTeX en que se pide escribir el resultado

DeepSeek-R1-Distill-Qwen-1.5B
razona y después responde

`<think>`

Alright, so I have this problem here about a robe that takes 2 bolts of blue fiber and half that much white fiber.

...

Wait, is that right? Let me double-check.

...

`</think>`

Thus, the total number of bolts needed is `\boxed{3}`.

1.708 tokens
responde 3: correcto

Del ajuste con instrucciones al chat

El SFT de un modelo de chat usa mensajes con roles. Una plantilla los convierte en una sola secuencia con tokens especiales, y la pérdida se calcula solo sobre la respuesta.

system <|im_start|>system ↵ You are a helpful assistant . <|im_end|> ↵ m = 0

user <|im_start|>user ↵ Translate to Spanish : The green witch arrived . <|im_end|> ↵ m = 0

assistant: plantilla <|im_start|>assistant ↵ <think> ↵ ↵ </think> ↵ ↵ m = 0

assistant: respuesta La bruja verde llegó . <|im_end|> m = 1

32 piezas con m = 0; 7 piezas de respuesta con m = 1

<|im_start|>, <|im_end|>: abren y cierran cada mensaje; vienen del formato ChatML de OpenAI, e «im» se lee como input message.
<think>, </think>: delimitan el razonamiento; quedan vacíos cuando ese modo está desactivado. ↵: salto de línea.

Los datos de SFT

Los conjuntos crecieron de miles a cientos de miles de ejemplos, y la mayor parte de las respuestas ya no la escribe una persona.


Modelo	Ejemplos	Quién escribe las respuestas
LIMA (LLaMA 65B)	1.000	los autores, curadas a mano
InstructGPT	≈13.000	anotadores contratados
Llama 2	27.540	anotadores contratados
Zephyr (Mistral 7B)	≈200.000	ChatGPT, en conversaciones sintéticas
DeepSeek-R1	≈800.000	el propio modelo, filtrado
Tulu 3 (Llama 3.1)	939.344	mezcla de humanos y de otros LLM

LIMA: Less Is More for Alignment. Zhou et al., NeurIPS 2023; Ouyang et al., NeurIPS 2022; Touvron et al., 2023; Tunstall et al., 2023; DeepSeek-AI, Nature 2025; Lambert et al., 2024.

Rejection sampling

El modelo genera K respuestas a un problema con solución conocida y se conservan las que llegan a esa solución. Llegan por caminos escritos distintos, y el SFT se entrena con el texto completo de cada una.

Problema: «A robe takes 2 bolts of blue fiber and half that much white fiber. How many bolts in total does it take?» solución: 3
Instrucción al modelo: razonar paso a paso y escribir el resultado final dentro de `\boxed{ }`, la marca de LaTeX para un recuadro.



Lo que el SFT no hace

El SFT imita respuestas demostradas. Para enseñar qué respuesta es peor que otra hace falta una señal de contraste.

SFT

pares (x, y) : solo respuestas buenas

La pérdida sube la probabilidad de cada token de y .

Una respuesta mala nunca aparece en el entrenamiento.

En el rejection sampling, las 3 respuestas incorrectas se descartan: nada le dice al modelo que no las genere.

Preferencias

para el mismo x , dos respuestas: y_w gana (win) e y_l pierde (lose)

La pérdida sube la probabilidad de y_w y baja la de y_l .

La señal es una comparación: cuál de dos respuestas es mejor.

Comparar es más fácil que escribir la respuesta ideal, para una persona y para un LLM que evalúa.

Fuente

Ouyang et al., NeurIPS 2022; Rafailov et al., NeurIPS 2023.

Datos de preferencia

Cada ejemplo es un prompt x con una respuesta preferida y_w y una rechazada y_l . Las comparaciones las hacen personas o un LLM que evalúa.

Dataset	Pares	Quién compara	De dónde salen las respuestas
HH-RLHF	160.800	personas	modelos de Anthropic
Llama 2	1.418.091	anotadores de Meta	versiones de Llama 2
UltraFeedback	61.135	GPT-4	17 modelos distintos
Tulu 3	354.192	GPT-4o	el modelo ajustado y otros

HH-RLHF: helpful and harmless, con RL desde preferencias humanas. Bai et al., 2022; Touvron et al., 2023; Cui et al., ICML 2024; Lambert et al., 2024.

Preferencias como probabilidades

A cada respuesta se le asigna un puntaje r . La probabilidad de preferir una sobre otra es la logística de la diferencia de puntajes.

$$P(y_w \succ y_l | x) = \frac{s_w}{s_w + s_l}, \quad s = e^{r(x, y)} > 0$$

$y_w \succ y_l$: y_w se prefiere a y_l ; s : fuerza de cada respuesta

$$= \frac{e^{r_w}}{e^{r_w} + e^{r_l}} = \frac{e^{r_w}/e^{r_w}}{e^{r_w}/e^{r_w} + e^{r_l}/e^{r_w}} = \frac{1}{1 + e^{-(r_w - r_l)}}$$


se divide arriba y abajo por e^{r_w}

$$= \sigma(r_w - r_l)$$

la logística de la diferencia de puntajes

$$\log \frac{P}{1 - P} = r_w - r_l$$

la diferencia es el logit; $r_w = r(x, y_w)$, $r_l = r(x, y_l)$



La fuerza de cada respuesta

$s = e^r$ es siempre positiva. Gana la comparación con probabilidad igual a su fracción de la fuerza total.

De fracción a logística

Al dividir numerador y denominador por la fuerza de y_w , solo queda la diferencia $r_w - r_l$.

Un par medido

Puntajes 2,58 y 0,43: diferencia 2,15, preferencia 0,90.

El modelo de recompensa



Un LLM con el cabezal U reemplazado por una capa lineal que devuelve un escalar. Se entrena con los pares de preferencia y la pérdida de Bradley-Terry.

$$r_\phi(x, y) = \mathbf{w}^\top \mathbf{h}_T, \quad \mathbf{w} \in \mathbb{R}^d$$

$\mathbf{h}_T$: salida del último bloque en la última posición; d : su dimensión

$$\mathcal{L}(\phi) = -\frac{1}{N} \sum_{n=1}^N \log \sigma \left(r_\phi(x^{(n)}, y_w^{(n)}) - r_\phi(x^{(n)}, y_l^{(n)}) \right)$$

ϕ : los pesos del LLM y $\mathbf{w}$



Ouyang et al., NeurIPS 2022. Medido con Skywork-Reward-V2-Qwen3-0.6B.

Un LLM como política

El mismo modelo genera varias respuestas al mismo prompt. La línea base b es el promedio de sus recompensas: las que lo superan se vuelven más probables y las que quedan bajo él, menos.

$$\log \pi_{\theta}(y \mid x) = \sum_{t=1}^{|y|} \log \pi_{\theta}(y_t \mid x, y_{<t})$$

la política es el LLM

$$J(\theta) = \mathbb{E}_{x \sim \mathcal{D}, y \sim \pi_{\theta}(\cdot \mid x)} [r(x, y)]$$


$\mathcal{D}$: los prompts; $y \sim \pi_{\theta}$: respuesta muestreada del modelo

$$\nabla_{\theta} J = \mathbb{E} \left[(r(x, y) - b(x)) \nabla_{\theta} \log \pi_{\theta}(y \mid x) \right]$$

$A = r - b$: la ventaja


$$b(x) = \mathbb{E}_{y \sim \pi_{\theta}(\cdot \mid x)} [r(x, y)] \approx \frac{1}{G} \sum_{i=1}^G r(x, y_i), \quad y_i \sim \pi_{\theta}(\cdot \mid x)$$

línea base: promedio de G respuestas al mismo x , del mismo modelo



RLHF

Un modelo de recompensa r_ϕ aprende de preferencias humanas, y el LLM se entrena con RL para maximizar lo que r_ϕ puntúa. θ son todos los parámetros del LLM, de todas sus capas, y se actualizan todos.



Stiennon et al., NeurIPS 2020; Ouyang et al., NeurIPS 2022. β : peso de la penalización por alejarse del modelo después del SFT.


La penalización KL

El modelo aprende: la masa va hacia las respuestas con más recompensa. Pero una respuesta que π_{ref} casi no genera, como y_5 , no se queda con todo.

$$\max_{\theta} \mathbb{E}_{x \sim \mathcal{D}, y \sim \pi_{\theta}} [r_{\phi}(x, y)] - \beta D_{\text{KL}}(\pi_{\theta} \parallel \pi_{\text{ref}}) \quad r_{\phi}: \text{ el modelo de recompensa, fijo}$$

$$D_{\text{KL}}(\pi_{\theta} \parallel \pi_{\text{ref}}) = \mathbb{E}_{y \sim \pi_{\theta}} \left[\log \frac{\pi_{\theta}(y | x)}{\pi_{\text{ref}}(y | x)} \right] \geq 0 \quad \text{vale 0 solo si las dos distribuciones son iguales}$$

$$R(x, y) = r_{\phi}(x, y) - \beta \log \frac{\pi_{\theta}(y | x)}{\pi_{\text{ref}}(y | x)} \quad \text{la recompensa que recibe cada respuesta generada}$$



r_{ϕ} : $y_1 = 1,2$ $y_2 = 0,9$ $y_3 = 0,4$ $y_4 = 0,1$ $y_5 = 2,5$ y_5 es un error del RM: puntaje alto a una mala respuesta

Cada panel con β es la solución del objetivo: $\pi_{\theta}(y | x) \propto \pi_{\text{ref}}(y | x) \cdot e^{r_{\phi}(x, y)/\beta}$. Valores ilustrativos.

Además, PPO usa clipping: en cada actualización, la probabilidad de un token no puede cambiar más de un 20 %.

Ouyang et al., NeurIPS 2022; Schulman et al., 2017. Distribuciones ilustrativas.

Por qué un value model

La recompensa llega una vez, al final de la respuesta. Para saber qué tokens la causaron, PPO entrena un value model V_ψ que estima, en cada prefijo, la recompensa que se espera obtener.

Problema: «A robe takes 2 bolts of blue fiber and half that much white fiber. How many bolts in total does it take?»

Una bata lleva 2 rollos de fibra azul y la mitad de fibra blanca. ¿Cuántos rollos lleva en total? Solución: 3

fragmentos de la respuesta, en orden (cada caja agrupa algunos tokens)

respuesta correcta Blue: 2 bolts. White: half of 2 is **1.** Total: 2 + 1 = 3 recompensa $R = 1$

recompensa esperada (V_ψ) 0,62 0,62 **0,93** 0,95 1,00

respuesta incorrecta Blue: 2 bolts. White: half of 2 is **4.** Total: 2 + 4 = 6 recompensa $R = 0$

recompensa esperada (V_ψ) 0,62 0,62 0,08 0,05 0,00



aquí cae la recompensa esperada: este fragmento es el error

π_{ref} referencia

un LLM con su cabezal U: devuelve una distribución sobre el vocabulario.
Fijo. Sirve para la penalización KL.

V_ψ value model (ψ : sus pesos)

un LLM con cabezal escalar: devuelve un número, la recompensa esperada.
Se entrena. Sirve para la ventaja.

PPO: el value model y los cuatro modelos

V_ψ se entrena por regresión hacia la recompensa obtenida, y la ventaja de cada token es lo obtenido menos lo que V_ψ esperaba. Dos modelos se entrenan y dos quedan fijos.

$$V_\psi(x, y_{<t}) \approx \mathbb{E}[R \mid x, y_{<t}]$$


la recompensa que se espera desde el prefijo $y_{<t}$

$$A_t = R(x, y) - V_\psi(x, y_{<t})$$

cuánto mejor resultó que lo esperado

$$\mathcal{L}(\psi) = \frac{1}{|y|} \sum_{t=1}^{|y|} (V_\psi(x, y_{<t}) - R(x, y))^2$$

el value model se entrena por regresión



Schulman et al., 2017; Schulman et al., ICLR 2016; Ouyang et al., NeurIPS 2022.

Direct Preference Optimization

El objetivo con KL tiene una solución exacta. Despejando de ella la recompensa, la pérdida de Bradley-Terry queda escrita con π_θ y π_{ref} , sin modelo de recompensa ni RL.

$$\pi^*(y | x) = \frac{1}{Z(x)} \pi_{\text{ref}}(y | x) e^{r(x,y)/\beta}$$

la política óptima del objetivo con KL

$$Z(x) = \sum_y \pi_{\text{ref}}(y | x) e^{r(x,y)/\beta}$$


normaliza: suma sobre todas las respuestas posibles

$$r(x, y) = \beta \log \frac{\pi^*(y | x)}{\pi_{\text{ref}}(y | x)} + \beta \log Z(x)$$

despejando la recompensa

$$\mathcal{L}_{\text{DPO}}(\theta) = -\frac{1}{N} \sum_{n=1}^N \log \sigma \left(\beta \log \frac{\pi_\theta(y_w^{(n)} | x^{(n)})}{\pi_{\text{ref}}(y_w^{(n)} | x^{(n)})} - \beta \log \frac{\pi_\theta(y_l^{(n)} | x^{(n)})}{\pi_{\text{ref}}(y_l^{(n)} | x^{(n)})} \right)$$

$\beta \log Z(x)$ se cancela en la diferencia



sin modelo de recompensa y sin generar respuestas: los pares son fijos

Recompensas verificables

Si la solución se puede revisar, la recompensa la da un verificador: un programa construido para una tarea específica. Abajo, uno de matemática.

$$v(x, y) = \begin{cases} \alpha & \text{si la respuesta de } y \text{ es correcta} \\ 0 & \text{si no} \end{cases}$$

el verificador; $\alpha=10$ en Tülu 3

$$\max_{\theta} \quad \mathbb{E}_{x \sim \mathcal{D}, y \sim \pi_{\theta}} [v(x, y)] - \beta D_{\text{KL}}(\pi_{\theta}(\cdot | x) \| \pi_{\text{ref}}(\cdot | x))$$

el objetivo de RLHF con v en lugar de r_{ϕ}

1. extrae el contenido del recuadro 2. interpreta lo convierte en una expresión matemática 3. compara con la solución, aunque esté escrita distinto 4. recompensa α si son iguales; si no, 0				
solución	final de la respuesta del modelo	extraído	¿igual?	r
3	... so the total is \boxed{3}.	3	sí	α
3	... 2 + 2/2 = \boxed{\frac{6}{2}}	3	sí	α
3	... it takes \boxed{6} bolts in total.	6	no	0
3	... Therefore, the answer is 3.	sin recuadro	no	0
$\frac{1}{2}$	... the probability is \boxed{0.5}	1/2	sí	α
$x^2 + 2x + 1$	... which factors as \boxed{(x+1)^2}	$(x + 1)^2$	sí	α

Group Relative Policy Optimization

Para cada prompt se generan G respuestas, y cada una se compara con la media del grupo: las que superan el promedio suben de probabilidad y las demás bajan. No hay value model.

$$y_1, \dots, y_G \sim \pi_\theta(\cdot | x), \quad r_i = v(x, y_i)$$


G respuestas al mismo prompt, cada una con su recompensa

$$\mathbf{A}_i = \frac{r_i - \text{media}(r_1, \dots, r_G)}{\text{desv}(r_1, \dots, r_G)}$$

la ventaja: cuánto mejor que el promedio del grupo

$$J(\theta) = \mathbb{E} \left[\frac{1}{G} \sum_{i=1}^G \mathbf{A}_i \frac{1}{|y_i|} \log \pi_\theta(y_i | x) \right] - \beta D_{\text{KL}}(\pi_\theta \| \pi_{\text{ref}})$$

J : el objetivo que se maximiza; $|y_i|$: largo de y_i en tokens



Shao et al., 2024 (DeepSeekMath); DeepSeek-AI, Nature 2025. J : el objetivo que se maximiza.

Un grupo de GRPO

Ocho respuestas al mismo problema, con la recompensa del verificador. Media 0,625 y desviación 0,484: las correctas reciben ventaja +0,77 y las incorrectas -1,29.

i	comienzo de la respuesta y_i	resultado	tokens	r_i	A_i	
1	To determine the total number of bolts of fiber ne ...	3	245	1	+0,77	sube
2	The robe takes 2 times the amount of blue fibers t ...	sin recuadro	52	0	-1,29	baja
3	Let's break down the problem step by step to find ...	6	278	0	-1,29	baja
4	For this problem, we need to calculate the number ...	3	220	1	+0,77	sube
5	It takes a total of 6 bolts of fabric because 1 + ...	6	45	0	-1,29	baja
6	Step 1: Determine the amount of blue fiber needed ...	3	184	1	+0,77	sube
7	To determine the total number of bolts of fiber ne ...	3	272	1	+0,77	sube
8	To determine the total number of bolts of fiber re ...	3	219	1	+0,77	sube

media 0,625 · desviación 0,484 · resultado: el número escrito en el recuadro, comparado con 3