



IIC3670 Procesamiento de Lenguaje Natural

<https://github.com/marcelomendoza/IIC3670>


- AGENTES IA -

Agentes IA

Definición: Un agente es un sistema informático capaz de percibir su entorno a través de sensores, actuar sobre él mediante actuadores, y tomar decisiones autónomas para alcanzar objetivos asignados.


Rusell, S., Norvig, P. AI: A Modern Approach, 4th Ed. 2022

LLMs en agentes:




Agentes IA

Agentic AI: agentes AI que se especializan, manejan memoria, incorporan razonamiento, planificación y son orquestados. Son una evolución arquitectónica de los agentes, operando a nivel de planificación y coordinación de tareas.



Agentes IA


Agentic AI: el proceso de planificación es central para delegar responsabilidades.



- RAG -


Agentes IA

RAG (Retrieval Augmented Generation): Probablemente la aplicación de agentes IA más usada. El contexto del prompt lo busca el agente en fuentes externas al LLM.



Information Retrieval

Information Retrieval: un sistema IR requiere de un índice invertido para manejar *keywords*, representaciones vectoriales de documentos/consultas y un algoritmo de *ranking*. Primero los documentos se indexan. Luego se pueden correr consultas sobre el sistema, al cual se le conoce como motor de consultas.



Un sistema IR convencional construye representaciones a nivel de palabras de cada documento. Suelen usar una función de *scoring* para medir el alineamiento entre q y d :

$$\text{score}(q, d) = \sum_{t \in q} \frac{\text{tf-idf}(t, q)}{\sqrt{\sum_{q_i \in q} \text{tf-idf}^2(q_i, q)}} \cdot \frac{\text{tf-idf}(t, d)}{\sqrt{\sum_{d_i \in d} \text{tf-idf}^2(d_i, d)}}$$

donde $\text{tf-idf}(t, d) = \text{tf}_{t,d} \cdot \text{idf}_t$ y $\text{tf}_{t,d} = \begin{cases} 1 + \log_{10} \text{count}(t, d) & \text{if } \text{count}(t, d) > 0 \\ 0 & \text{otherwise} \end{cases}$

$$\text{idf}_t = \log_{10} \frac{N}{\text{df}_t}$$


Dense Information Retrieval (Vector DB)

Dense Information Retrieval: un sistema IR moderno se basa en *embeddings* de documentos. Entonces, las representaciones son densas. Esto aborda el problema del *mismatch* de palabras de q y d .

Podemos usar un encoder (transformer pre-entrenado) para calcular el score de q y d . Hay varias formas de hacer esto. Veamos una que se basa en codificar el par usando [CLS]:


Esto es equivalente a usar este esquema de codificación:

$$\mathbf{z} = \text{BERT}(q; [\text{SEP}]; d)[\text{CLS}]$$
$$\text{score}(q, d) = \text{softmax}(\mathbf{U}(\mathbf{z}))$$



Dense Information Retrieval (Vector DB)

Dense Information Retrieval: otra forma de codificar q y d para calcular el scoring es usar un encoder para q y d por separado, cada uno con un [CLS]:



Esto es equivalente a usar este esquema de codificación:

$$\mathbf{z}_q = \text{BERT}_Q(q) [\text{CLS}]$$

$$\mathbf{z}_d = \text{BERT}_D(d) [\text{CLS}]$$


$$\text{score}(q, d) = \mathbf{z}_q \cdot \mathbf{z}_d$$



Karpukhin, V., Oğuz, B., Min, S., Lewis, P., Wu, L., Edunov, S., Chen, D., & Yih, W.-t. (2020). Dense passage retrieval for open-domain question answering. EMNLP, 6769–6781

Dense Information Retrieval (Vector DB)

ColBERT: Usa encoders para q y d por separado. En lugar de usar *embeddings* a nivel de q y d , lo hace a nivel de tokens. La función de *scoring* se calcula como la suma de la similitud máxima entre los tokens de q y d .



Esto es equivalente a usar este esquema de *scoring*:

$$\text{score}(q, d) = \sum_{i=1}^N \max_{j=1}^m \mathbf{E}_{q_i} \cdot \mathbf{E}_{d_j}$$



Khattab, O., Potts, C., & Zaharia, M. (2021). Relevance-guided supervision for OpenQA with ColBERT. Transactions of the Association for Computational Linguistics, 9, 929–944

RAG + Dense Vector Retrieval

RAG hace uso de *dense vector retrieval* para recuperar pasajes que pueda incrustar en el prompt. Sin RAG un LLM trabaja en modo completación condicionado a la siguiente información:

$$p(x_1, \dots, x_n) = \prod_{i=1}^n p([Q:] ; q ; [A:] ; x_{<i})$$

donde el prompt está estructurado con Q: y A: para indicar la pregunta y la respuesta que se le pide al LLM.

Al usar RAG incrustamos los pasajes en el prompt:

Schematic of a RAG Prompt

retrieved passage 1

retrieved passage 2

...

retrieved passage n

Based on these texts, answer this question: Q: Who wrote the book ‘‘The Origin of Species’’? A:

RAG + Dense Vector Retrieval

Incrustar pasajes en el prompt es equivalente a hacer completación de texto condicionada sobre los pasajes recuperados:

$$p(x_1, \dots, x_n) = \prod_{i=1}^n p(x_i | \underset{\substack{\uparrow \\ \text{pasajes recuperados usando } q}}{R(q)} ; \text{prompt} ; [Q:] ; q ; [A:] ; x_{<i})$$

Mejorar el contexto de un prompt ayuda al LLM a encontrar la respuesta.

- EVALUACIÓN QA -

GLUE: General Language Understanding Evaluation

CoLA (Corpus of Linguistic Acceptability): Esta es una tarea de clasificación binaria en la que los sistemas deben predecir si una oración en inglés es gramaticalmente correcta o no.

SST-2 (Stanford Sentiment Treebank): Esta es otra tarea de clasificación binaria en la que los sistemas deben predecir el sentimiento de una oración, ya sea positivo o negativo.

MRPC (Microsoft Research Paraphrase Corpus): En esta tarea, los sistemas deben determinar si dos oraciones son paráfrasis la una de la otra.

STS-B (Semantic Textual Similarity Benchmark): Aquí, los sistemas deben predecir qué tan similar es el significado de dos oraciones en una escala de 0 a 5.

QQP (Quora Question Pairs): En esta tarea, los sistemas deben determinar si dos preguntas son semánticamente equivalentes.

MNLI (Multi-Genre Natural Language Inference): Esta tarea requiere que los sistemas determinen la relación entre una oración de premisa y una oración de hipótesis: si la hipótesis es un entailment, una contradicción, o neutra.

QNLI (Question Natural Language Inference): Esta es una versión de la tarea de Natural Language Inference, en la que se presenta a los sistemas una pregunta y un párrafo, y deben determinar si la respuesta a la pregunta se puede inferir del párrafo.

RTE (Recognizing Textual Entailment): Similar a MNLI, pero las parejas de oraciones provienen de varios sets de datos anteriores.

WNLI (Winograd NLI): Esta tarea está diseñada para evaluar la capacidad de un sistema para la comprensión de la referencia de pronombres, es decir, a qué se refiere un pronombre en un texto.

 <https://gluebenchmark.com/>

SuperGLUE

BoolQ (BoolQ boolean questions): Los participantes deben responder preguntas de sí o no basadas en un párrafo corto de un artículo de Wikipedia.

CB (CommitmentBank): Se evalúa la capacidad de un modelo para predecir la postura de un hablante hacia una afirmación que ha hecho, basándose en la evidencia proporcionada.

COPA (Choice of Plausible Alternatives): Los modelos tienen que seleccionar la causa o el efecto más plausible de una situación dada.

MultiRC (Multi-Sentence Reading Comprehension): Los modelos deben responder preguntas sobre un párrafo, donde cada pregunta tiene múltiples respuestas correctas.

WiC (Word-in-Context): Esta tarea evalúa si un modelo puede entender el significado de una palabra en dos oraciones diferentes.

WSC (Winograd Schema Challenge): Es una tarea de resolución de la correferencia de pronombres que requiere una comprensión profunda del sentido común y del contexto.

RTE (Recognizing Textual Entailment): Los modelos deben determinar si una oración es verdadera (entails), es falsa (contradicts) o es neutral (neither) en base a una oración previa.

SQuAD v1.1 (Stanford Question Answering Dataset): Es una tarea de respuesta a preguntas basada en la comprensión de un párrafo.



<https://super.gluebenchmark.com/>

MMLU (Massive Multitask Language Understanding)

Diseñado para evaluar grandes modelos, como los LLMs. Está enfocado en preguntas de selección múltiple y cubre más de 57 temáticas incluyendo matemática, historia, leyes, entre otras.

Conceptual Physics	When you drop a ball from rest it accelerates downward at 9.8 m/s^2 . If you instead throw it downward assuming no air resistance its acceleration immediately after leaving your hand is	
	(A) 9.8 m/s^2	✓
	(B) more than 9.8 m/s^2	✗
	(C) less than 9.8 m/s^2	✗
College Mathematics	(D) Cannot say unless the speed of throw is given.	✗
	In the complex z -plane, the set of points satisfying the equation $z^2 = z ^2$ is a	
	(A) pair of points	✗
	(B) circle	✗
	(C) half-line	✗
	(D) line	✓

Se calcula un puntaje global entre $[0, 1]$, donde 1 indica desempeño perfecto.

Es un proyecto de evaluación abierta: <https://github.com/hendrycks/test>



Measuring Massive Multitask Language Understanding Dan Hendrycks, Collin Burns, Steven Basart, Andy Zou, Mantas Mazeika, Dawn Song, and Jacob Steinhardt (ICLR 2021).

MT Bench (Multiturn Benchmark)

MT Bench busca evaluar las capacidades multiturno de un LLM. Para esto, incorpora ejemplos con varias interacciones (multiturn interactions).

Category	Sample Questions	
Writing	1st Turn	Compose an engaging travel blog post about a recent trip to Hawaii, highlighting cultural experiences and must-see attractions.
	2nd Turn	Rewrite your previous response. Start every sentence with the letter A.
Math	1st Turn	Given that $f(x) = 4x^3 - 9x - 14$, find the value of $f(2)$.
	2nd Turn	Find x such that $f(x) = 0$.
Knowledge	1st Turn	Provide insights into the correlation between economic indicators such as GDP, inflation, and unemployment rates. Explain how fiscal and monetary policies ...
	2nd Turn	Now, explain them again like I'm five.



Lianmin Zheng Wei-Lin Chiang, Ying Sheng, Siyuan Zhuang, Zhanghao Wu, Yonghao Zhuang, Zi Lin, Zhuohan Li, Dacheng Li, Eric P. Xing, Hao Zhang, Joseph E. Gonzalez, Ion Stoica: Judging LLM-as-a-Judge with MT-Bench and Chatbot Arena. NeurIPS 2023.

ChatBot Arena

Se pueden comparar dos alternativas en base a votaciones de humanos (masivas, es decir, crowdsourcing). Los usuarios son libres de ingresar los prompts que deseen. Luego, ChatBotArena controla los prompts para resguardar diversidad temática usando BERT Topic. Luego pasan las evaluaciones de pares a ranking.

Ver Chatbot Arena leaderboard en: <https://chat.lmsys.org/>

Text4 days ago	WebDev21 hours ago	Vision15 days ago	Text-to-Image8 days ago
Rank (UB) ↑Model ↓Score ↓	Rank (UB) ↑Model ↓Score ↓	Rank (UB) ↑Model ↓Score ↓	Rank (UB) ↑Model ↓Score ↓
1  gemini-2.5-pro1451	1  GPT-5 (high)1478	1  gemini-2.5-pro1241	1  hunyuan-image-3.01161
1  claude-opus-4-1-20250805-thi...1447	1  Claude Opus 4.1 thinking-16k...1472	1  chatgpt-4o-latest-202503261234	1  gemini-2.5-flash-image-previ...1154
1  claude-sonnet-4-5-20250929-t...1445	1  Claude Opus 4.1 (20250805)1462	2  gpt-4.5-preview-2025-02-271220	3  imagen-4.0-ultra-generate-pr...1145
1  gpt-4.5-preview-2025-02-271441	4  Claude Sonnet 4.5 (thinking ...1421	3  o3-2025-04-161213	3  seedream-4-2k1144
2  chatgpt-4o-latest-202503261440	4  Gemini-2.5-Pro1401	3  gpt-5-chat1212	4  seedream-4-high-res-fal1134
2  o3-2025-04-161440	4  GLM-4.61398	3  gpt-4.1-2025-04-141207	5  imagen-4.0-generate-preview-...1131
2  claude-sonnet-4-5-202509291438	4  DeepSeek-R1-05281394	3  gemini-2.5-flash1203	7  gpt-image-11123
2  gpt-5-high1437	5  Claude Sonnet 4.51385	3  claude-opus-4-20250514-think...1203	7  seedream-4-fal1118
2  claude-opus-4-1-202508051437	6  Claude Opus 4 (20250514)1384	3  gemini-2.5-flash-preview-09-...1201	9  mai-image-11096
3  qwen3-max-preview1434	6  GLM-4.51381	3  hunyuan-vision-1.5-thinking1200	9  seedream-31082
View all	View all	View all	View all



Wei-Lin Chiang, Lianmin Zheng, Ying Sheng, Anastasios Nikolas Angelopoulos, Tianle Li, Dacheng Li, Hao Zhang, Banghua Zhu, Michael I. Jordan, Joseph E. Gonzalez, Ion Stoica: Chatbot Arena: An Open Platform for Evaluating LLMs by Human Preference. CoRR abs/2403.04132 (2024)

- FIN -

- FIN -

*... de las clases, faltan los proyectos y la
AF11 ...*